Bases de Datos

Clase 9: Almacenamiento y Índices

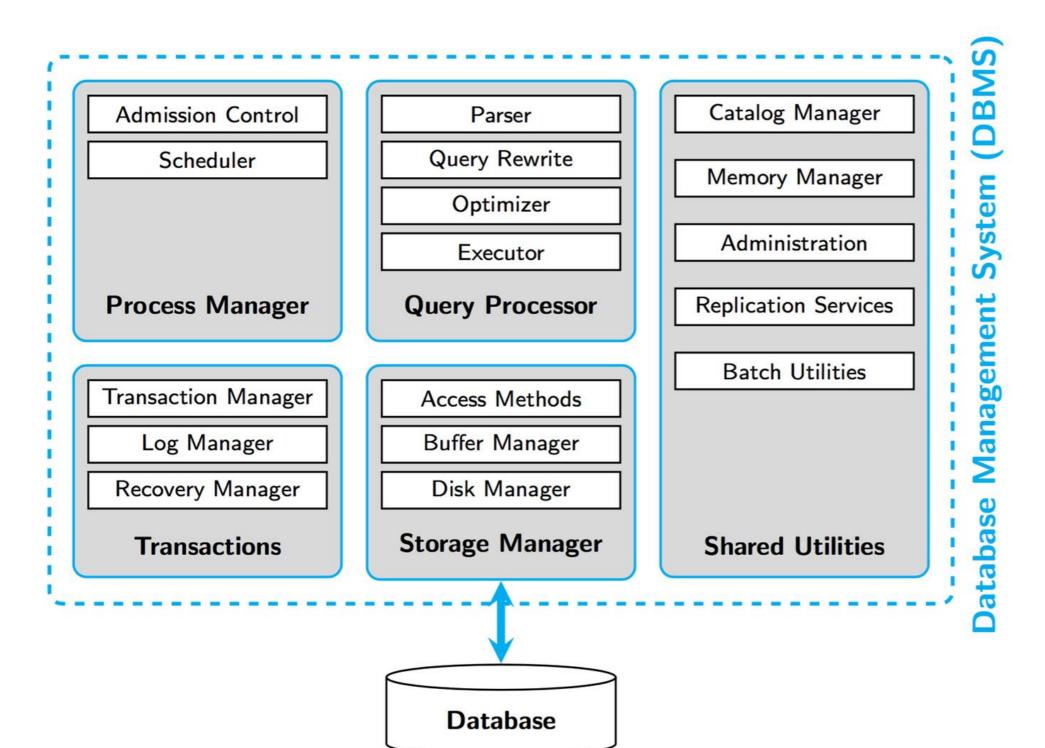
Hasta ahora

Usamos los DBMS como una caja negra: hacemos una consulta y el sistema se encarga

Pero, ¿cómo funciona realmente el sistema?

¿Cómo se evalúa una consulta?

Arquitectura de un DBMS



Ciclo de vida de una consulta

Paso 1: SQL → álgebra relacional

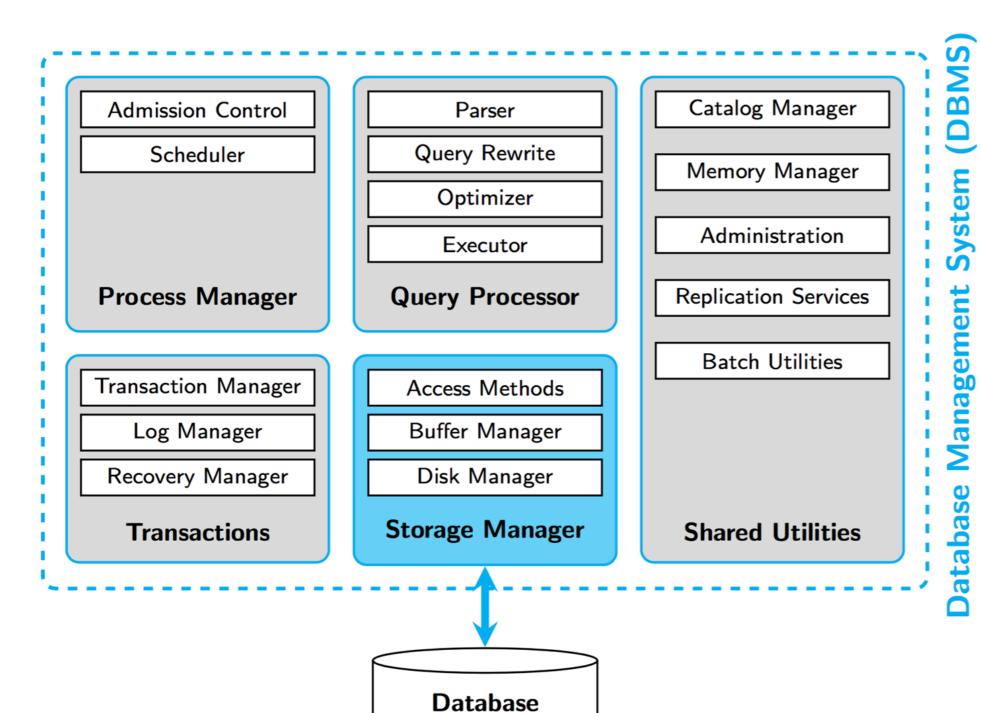
Paso 2: Reescritura → plan lógico

Paso 3: ¿Cuales algoritmos uso? → plan físico

Paso 4: Ejecución

¡Para ejecutar la consulta necesito acceder a los datos (en disco)!

Storage Manager



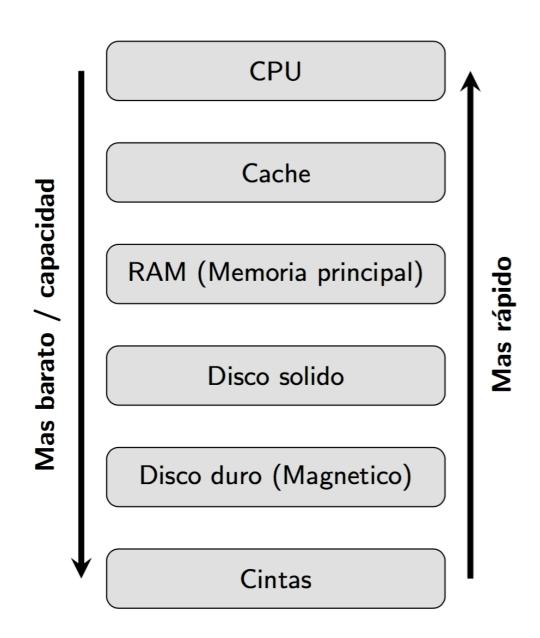
Almacenamiento

Almacenamiento

La base de datos necesita hacer persistente los datos en memoria secundaria

Almacenamiento

Jerarquía de Memoria



Disco Duro

Sector: unidad física mínima de almacenamiento para el Disco (definido por hardware)

Página: unidad lógica mínima de almacenamiento para el Sistema de Archivos (definido por OS/DBMS)

¡Un DBMS trabaja al nivel de página!

RAM

SO	so			

RAM

so	so			

RAM

so	so	Word	Word	Word			
----	----	------	------	------	--	--	--

	Word	Word	Word	
--	------	------	------	--

RAM

so	so	Word	Word	Word	Spotify	Spotify	
----	----	------	------	------	---------	---------	--

RAM

	Fifa	Fifa	Fifa	•••
--	------	------	------	-----

RAM

so

Disco Duro (espacio de swap)

	Fifa	Fifa	Fifa	
--	------	------	------	--

RAM

so	SO Wor	Spotify	Spotify			
----	--------	---------	---------	--	--	--

Disco Duro (espacio de swap)

	Word (Abierto)	Word (Abierto)		Fifa	Fifa	Fifa	
--	-------------------	-------------------	--	------	------	------	--

RAM

so	SO	Word	Spotify	Spotify	Fifa	Fifa	Fifa
----	----	------	---------	---------	------	------	------

Disco Duro (espacio de swap)

	Word (Abierto)	Word (Abierto)		Fifa	Fifa	Fifa	
--	-------------------	-------------------	--	------	------	------	--

RAM

so	so	Word	Spotify	Spotify	Fifa	Fifa	Fifa
----	----	------	---------	---------	------	------	------

Disco Duro (espacio de swap)

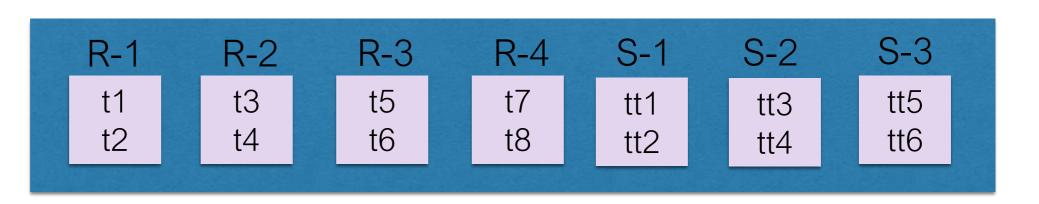
Disco Duro y DBMS

Los records de las bases de datos se almacenan en **páginas** de disco.

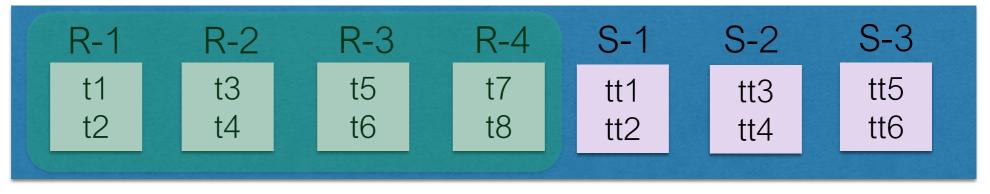
A medida que se hace necesario, las páginas son traídas a memoria principal (**buffer**)

Para trabajar con las tuplas de una relación, la base de datos carga la página con la tupla desde el disco

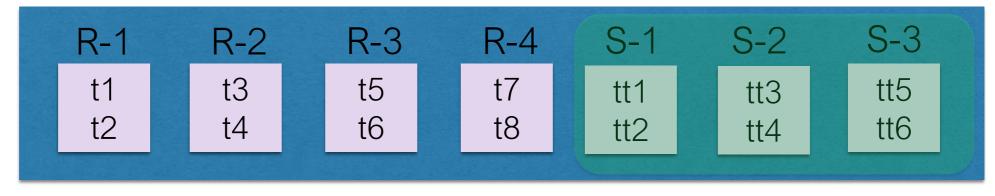
Para cargar estas páginas, la base de datos reserva un espacio en RAM llamado **Buffer**

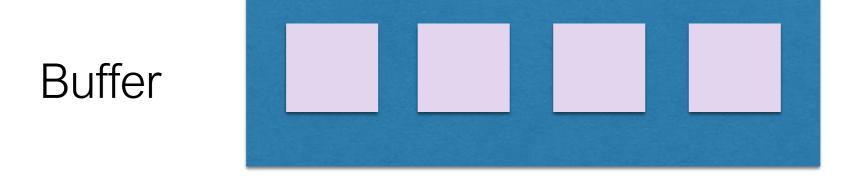


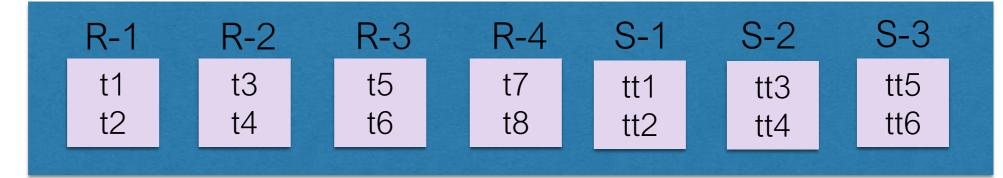
Relación R

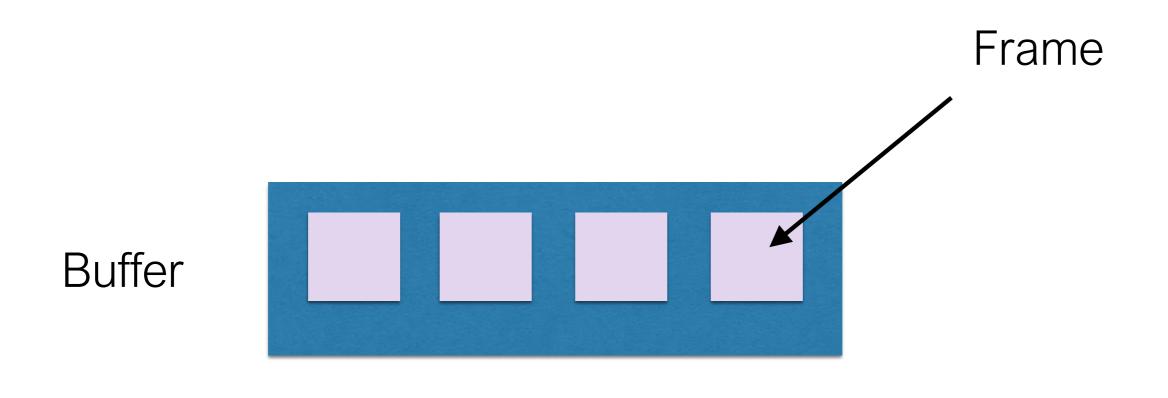


Relación S

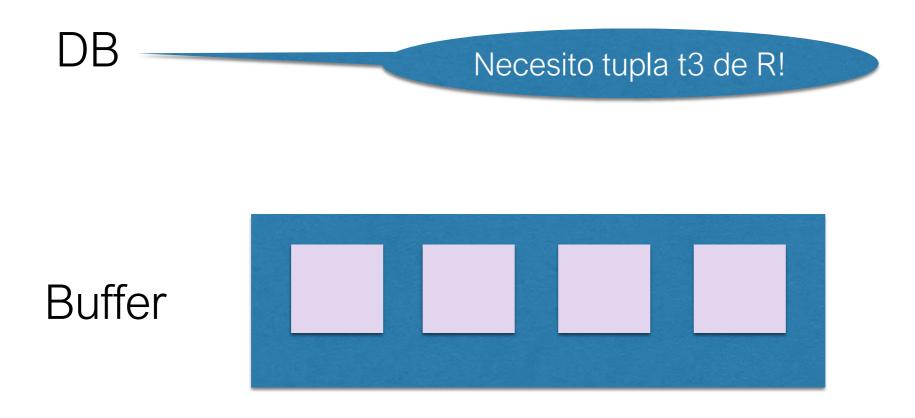




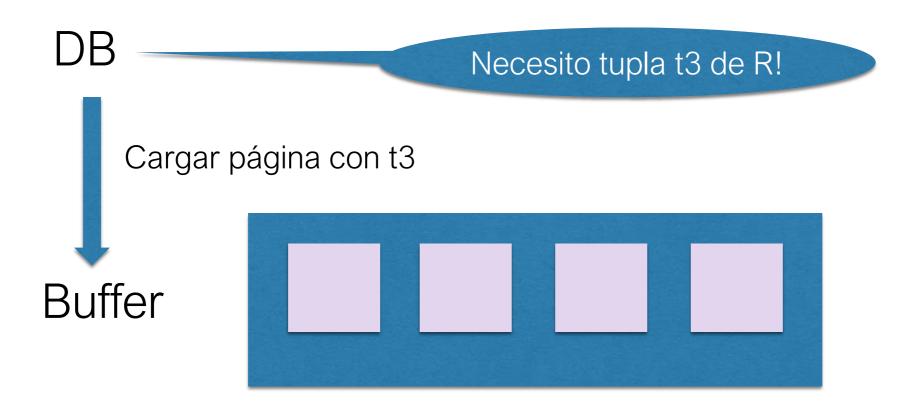


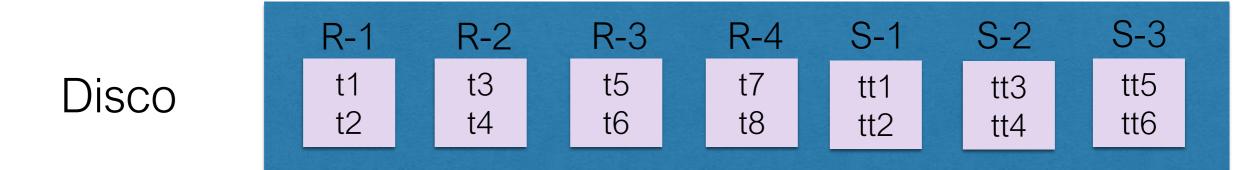


S-3 S-2 R-3 R-4 S-1 R-1 R-2 tt5 t5 t7 tt3 tt1 Disco t2 t4 t6 t8 tt6 tt2 tt4

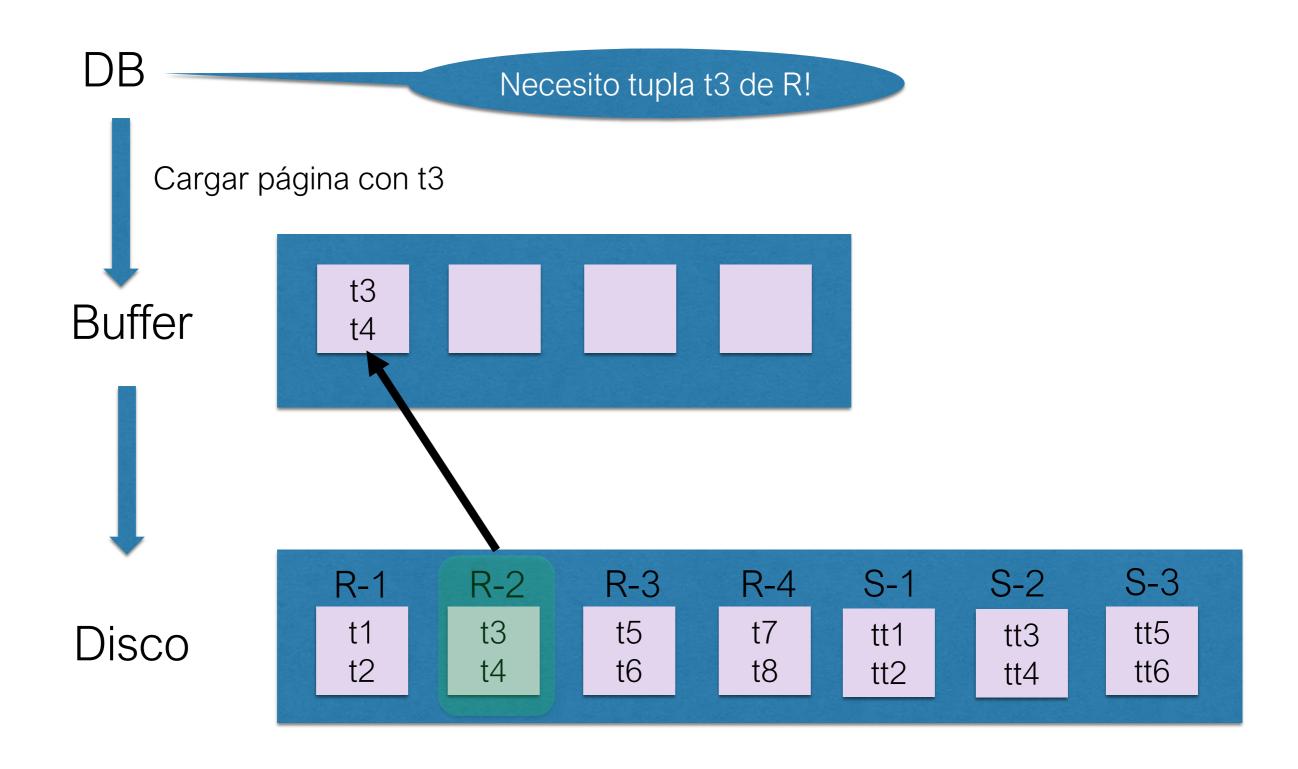






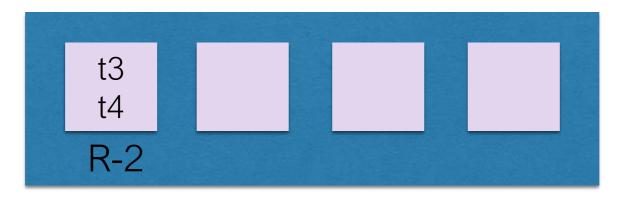




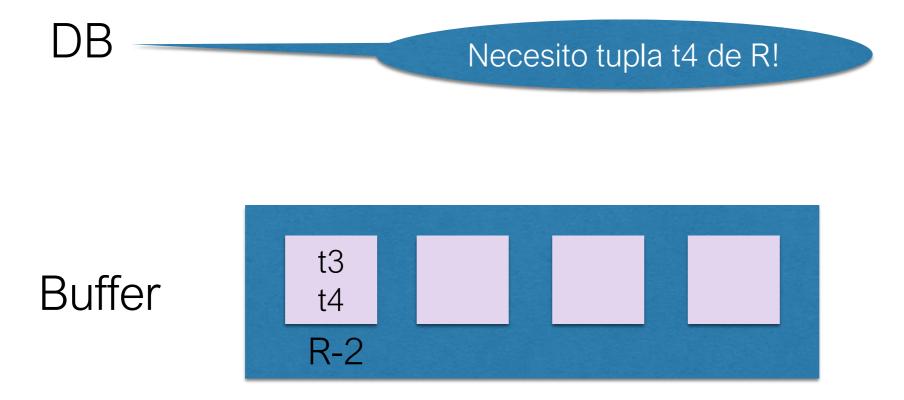


DB

Buffer







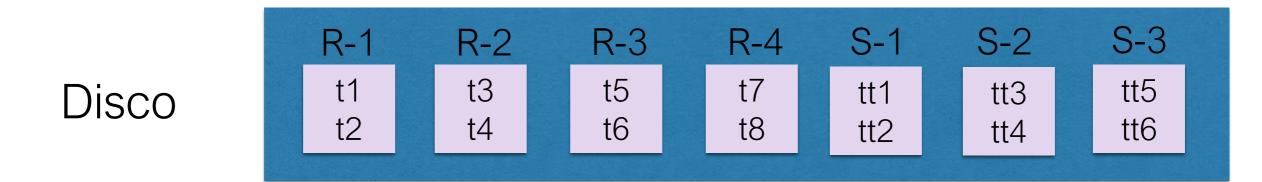
S-1 S-2 R-1 R-2 R-3 R-4 t5 t7 tt1 tt3 Disco t2 t4 t6 t8 tt2 tt4

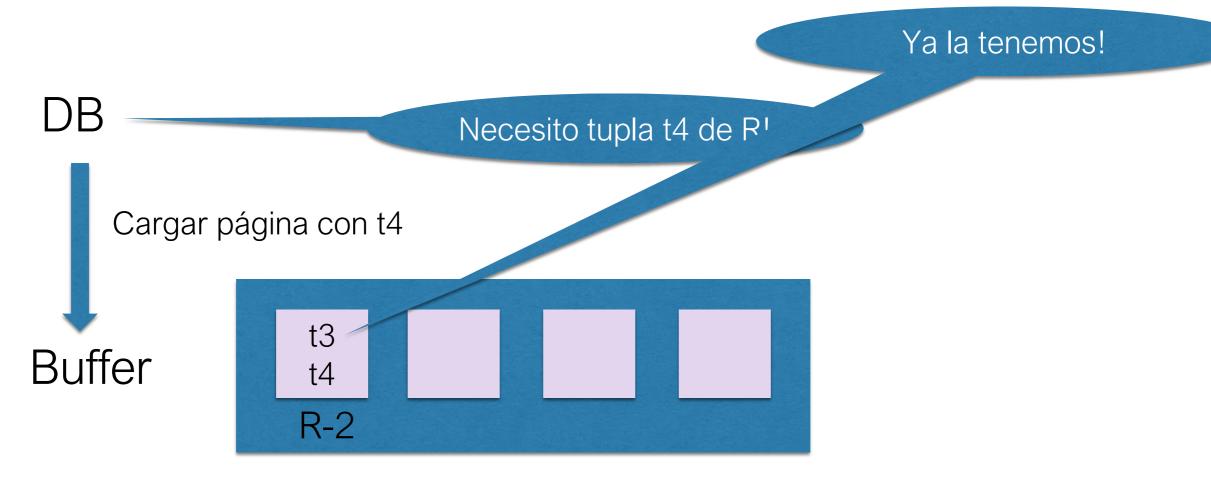
S-3

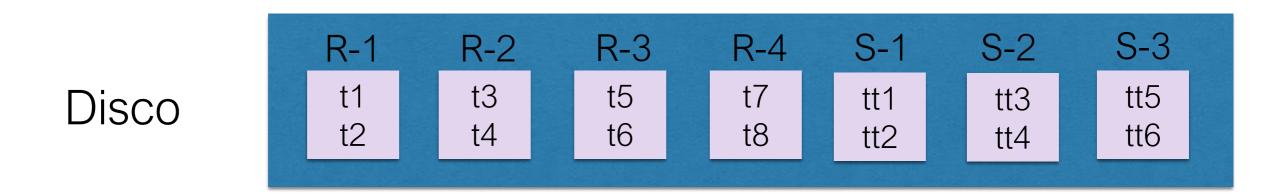
tt5

tt6









Demora en Búsqueda

"La diferencia de tiempo entre tener un dato en RAM versus traerlo de disco es comparable a la de tomar el sacapuntas del escritorio donde estoy sentado versus tomarme un avión a Punta Arenas para ir a buscarlo y regresar."

En general, lo más lento del DBMS es ir a buscar los datos a disco, por lo que queremos minimizar el número de I/O

Modelo de costos Memoria Principal vs. Memoria Secundaria



Memoria Secundaria

- Datos guardados en memoria secundaria
- La lectura se hace por páginas
- Una página tiene un tamaño de B tuplas



Memoria Principal

- Los datos son llevados a memoria principal
- La memoria tiene una capacidad de M páginas

Modelo de costos Memoria Principal vs. Memoria Secundaria

Se cuentan los accesos (lectura/escritura) a memoria secundaria



Memoria Secundaria

- Datos guardados en memoria secundaria
- La lectura se hace por páginas
- Una página tiene un tamaño de B tuplas

Los accesos a memoria principal son despreciables



Memoria Principal

- Los datos son llevados a memoria principal
- La memoria tiene una capacidad de M páginas

Modelo de costos



¿Cuánto cuesta leer n tuplas de memoria secundaria?

$$\left\lceil \frac{n}{B} \right\rceil$$

¿Cuántas páginas usa una relación R?

$$\left| \frac{|R|}{B} \right|$$



¿Y qué tiene que ver esto con Bases de Datos?

Cómo se guarda una tabla

Supongamos una tabla T(a int, b text) con 9 tuplas

Disco Duro

Tupla 1	Tupla 2	Tupla 3	Tupla 4	Tupla 5	Tupla 6	Tupla 7	Tupla 8	Tupla 9
Página 1		Página 2			Página 3			

Costo I/O (Input/Output)

¡El costo más grande de las bases de datos es traer las páginas del disco duro a memoria RAM!

Queremos responder las consultas haciendo la menor cantidad de lecturas al disco duro

Llamamos **costo de I/O** al número de páginas llevadas a memoria para responder una consulta

Disco Duro

Tupla 1	Tupla 2	Tupla 3	Tupla 4	Tupla 5	Tupla 6	Tupla 7	Tupla 8	Tupla 9
Página 1		Página 2			Página 3			

¿Cuál es el costo en I/O de hacer la siguiente consulta?

SELECT * FROM T

$$\left\lceil \frac{|R|}{B} \right\rceil = \left\lceil \frac{9}{3} \right\rceil$$

El costo es 3, porque debo leer las 3 páginas

Disco Duro

Tupla 1	Tupla 2	Tupla 3	Tupla 4	Tupla 5	Tupla 6	Tupla 7	Tupla 8	Tupla 9
Página 1		Página 2			Página 3			

¿Cuál es el costo en I/O de hacer la siguiente consulta?

SELECT T.a FROM T

$$\left\lceil \frac{|R|}{B} \right\rceil = \left\lceil \frac{9}{3} \right\rceil$$

El costo nuevamente es 3, porque debo leer las 3 páginas

Disco Duro

Tupla 1	Tupla 2	Tupla 3	Tupla 4	Tupla 5	Tupla 6	Tupla 7	Tupla 8	Tupla 9
Página 1		Página 2			Página 3			

¿Cuál es el costo en I/O de hacer la siguiente consulta?

SELECT * FROM T WHERE T.a = 4

El costo nuevamente es 3, porque debo leer las 3 páginas

$$\left\lceil \frac{|R|}{B} \right\rceil = \left\lceil \frac{9}{3} \right\rceil$$

Disco Duro

Tupla 1	Tupla 2	Tupla 3	Tupla 4	Tupla 5	Tupla 6	Tupla 7	Tupla 8	Tupla 9
Página 1		Página 2			Página 3			

¿Cuál es el costo en I/O de hacer la siguientes consultas?

SELECT * FROM T WHERE T.a = 4

SELECT * FROM T WHERE T.a >= 4

$$R$$

$$\left\lceil \frac{|R|}{B} \right\rceil$$

¿Podemos hacer esto mejor?

Herramientas que optimiza el acceso a los datos para una consulta o conjunto de consultas en particular

A un índice yo le indico que quiero las tuplas con cierto valor en un atributo (o con un valor en cierto rango)

El índice encontrará rápidamente las tuplas que que cumplan con la condición

(Idealmente un índice debe caber en RAM)

Consultas a Optimizar

Consultas por valor

```
SELECT *
FROM Table
WHERE Table.value = 'value'
```

Consultas por rango

```
SELECT *
FROM Table
WHERE Table.value >= 'value'
```

CREATE INDEX <nombre indice> ON table <atributo>

Las llaves primarias están indexadas por defecto

Supongamos que tengo la tabla:

en donde tenemos indexada la tabla por la primary key, que es el atributo uid

El índice normalmente es una colección de archivos que puede ir completo en memoria

Si hacemos la consulta:

SELECT * FROM Usuarios WHERE uid = 104

esta se resolverá con el índice, así evitaremos recorrer toda la tabla



Search Key: es el parámetro con el que busco algo en mi índice (por ejemplo, el uid de una tabla de usuarios)

Data Entry: la tupla que nos retorna el índice después de preguntar por una Search Key en particular

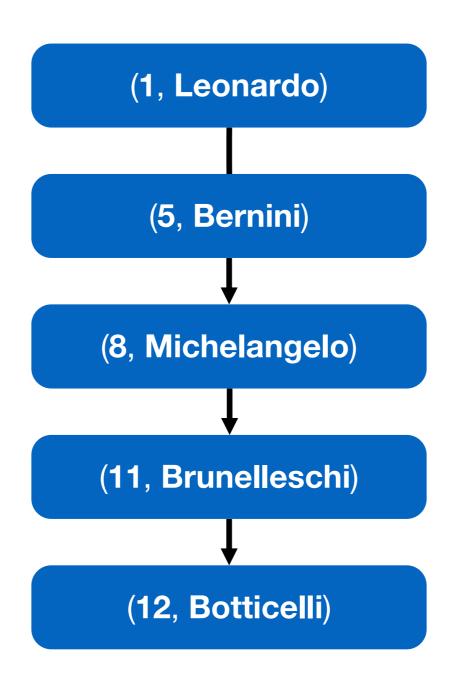
Por ahora: Data Entry = mi tupla

Mi esquema: Actores(aid, nombre)

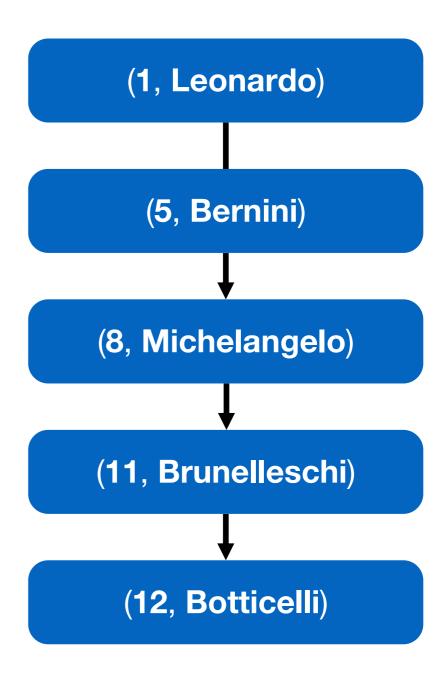
Instancia = una lista de tuplas en Python:

```
t = [
(1, Leonardo),
(5, Bernini),
(8, Michelangelo),
(11, Brunelleschi),
(12, Botticelli)
]
```

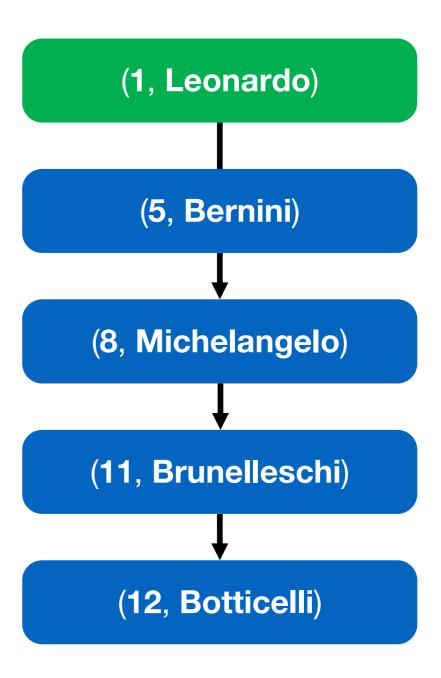
Lista ligada (versión básica)



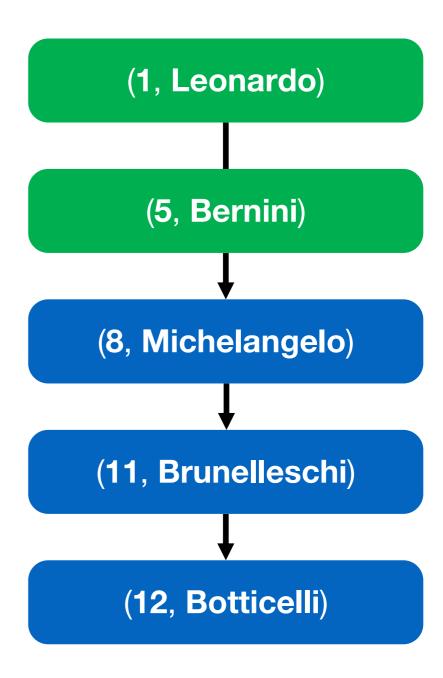
Lista ligada (versión básica)



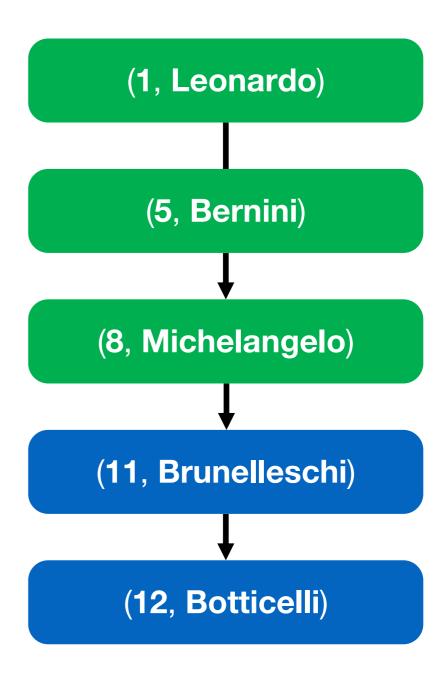
Lista ligada (versión básica)



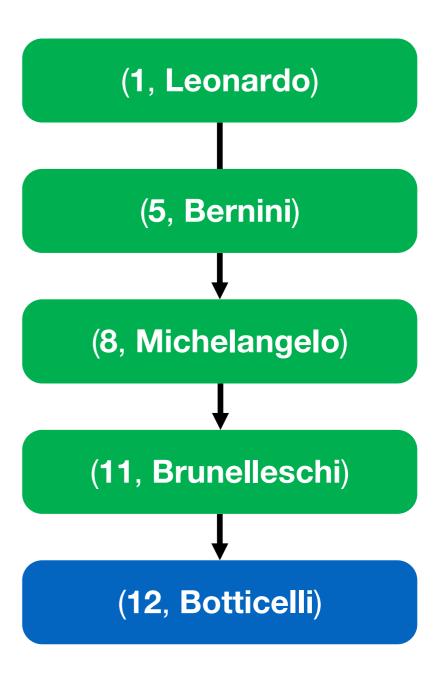
Lista ligada (versión básica)



Lista ligada (versión básica)



Lista ligada (versión básica)



Tablas de Hash

Iniciamos un número fijo de casilleros (buckets)

Cada tupla va a parar a un casillero según su id

Para esto utilizamos una función de hash.

Una función de hash es simplemente una función h que lleva elementos de un conjunto U a otro conjunto M (los casilleros/buckets)

Tablas de Hash

En el ejemplo, podemos tener una función de hash que recibe el id del artista y retorna un número de casillero

Si tenemos 5 casilleros, una posible función es módulo 5 (retorna el resto de la división por 5)

Tablas de Hash



Bucket	
0	
1	
2	
3	
4	

Tablas de Hash



(1, Leonardo)

Bucket	
0	
1	
2	
3	
4	

Tablas de Hash



(5, Bernini)

Bucket	
0	
1	(1, Leonardo)
2	
3	
4	

Tablas de Hash



Bucket	
0	(5, Bernini)
1	(1, Leonardo)
2	
3	
4	

Tablas de Hash

(8, Michelangelo)

(11, Brunelleschi)

(12, Botticelli)



Bucket	
0	(5, Bernini)
1	(1, Leonardo)
2	
3	
4	

Tablas de Hash



Bucket	
0	(5, Bernini)
1	(1, Leonardo) (11, Brunelleschi)
2	(12, Botticelli)
3	(8, Michelangelo)
4	

Tablas de Hash

Si queremos buscar el artista con identificador 12, ¿cómo lo hacemos ahora? ¿en cuántos pasos lo obtenemos?

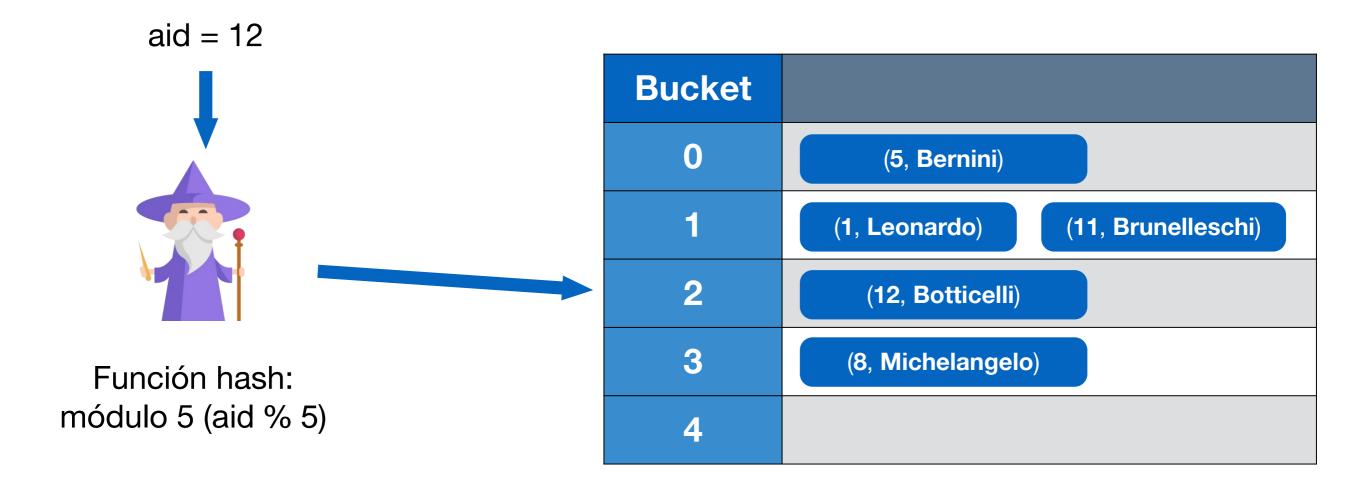
Tablas de Hash



Bucket	
0	(5, Bernini)
1	(1, Leonardo) (11, Brunelleschi)
2	(12, Botticelli)
3	(8, Michelangelo)
4	

Computamos el hash del número 12

Tablas de Hash



Y en 1 paso encontramos el casillero que le corresponde

Tablas de Hash

Notamos que hay colisiones, esto es, dos valores que van a parar al mismo casillero

En general, suponemos que las funciones de hash distribuyen uniforme

También suponemos que hay suficientes casilleros para que la búsqueda se haga en 1 paso (o no mucho más)

Hash Index

La idea es replicar el concepto de las tablas de hash pero en un sistema de bases de datos

Aquí nuestros casilleros serán páginas del disco duro

En cada página caben muchas tuplas

Recordemos que queremos encontrar tuplas para consultas de igualdad de forma rápida

SELECT * FROM Artistas A WHERE A.aid = 12

En este caso, rápido significa hacer la menor cantidad de I/O posible

Hash Index Ejemplo

Vamos a retomar el ejemplo de los artistas, pero ahora insertando las tuplas a una base de datos

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto

Ejemplo

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto



 $\left(0\right)$







Ejemplo

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto



(1, Leonardo)

2

3

Ejemplo

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto



(1, Leonardo)

2

3

Ejemplo

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto

0 (5, Bernini)

(1, Leonardo)

(2)

(8, Michelangelo)

Ejemplo

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto

0 (5, Bernini)	
----------------	--







Ejemplo

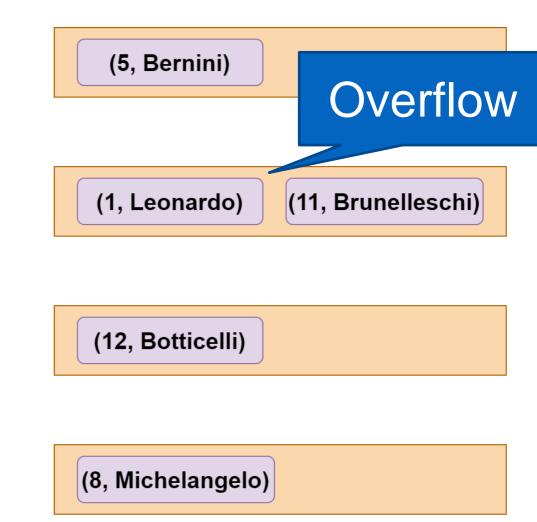
 $\left(\ \mathsf{0} \ \right)$

2

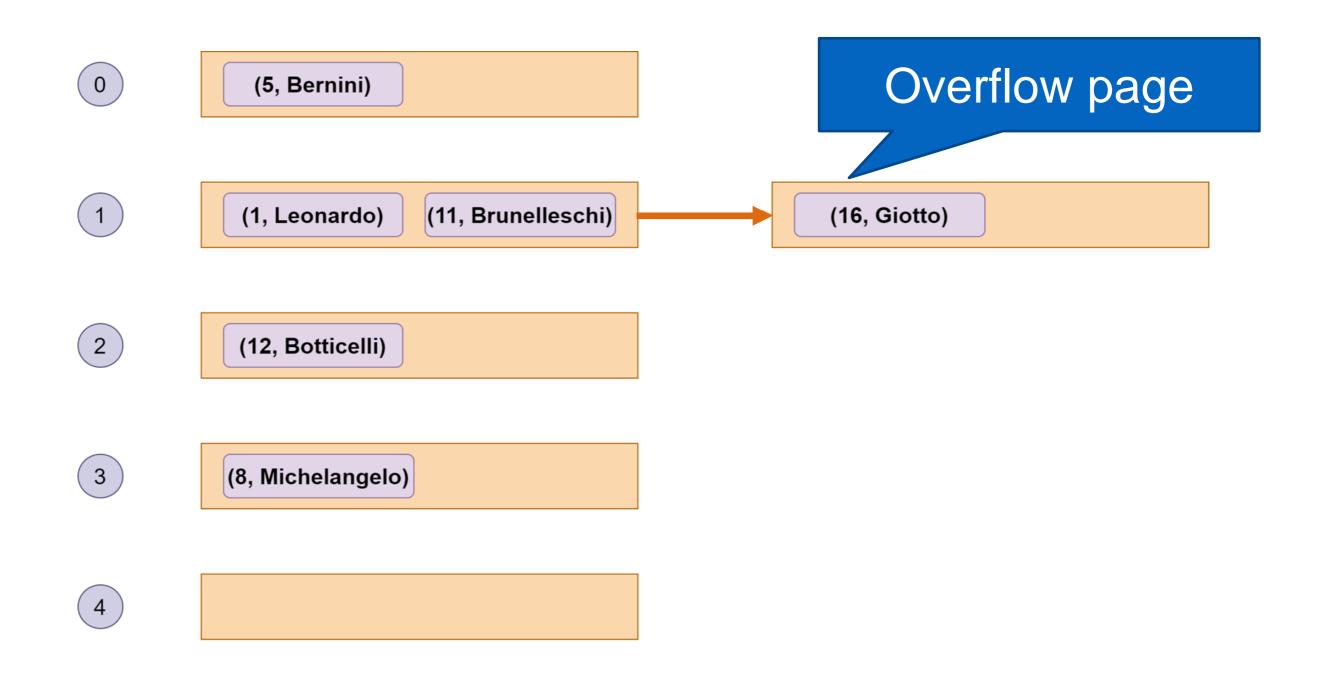
(3)

(4)

Artista.aid	Artista.nombre
1	Leonardo
5	Bernini
8	Michelangelo
11	Brunelleschi
12	Botticelli
16	Giotto



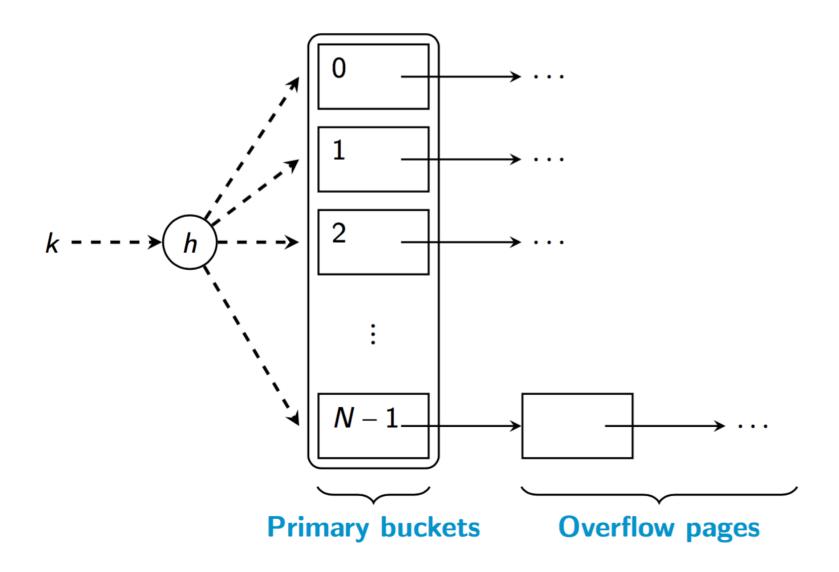
Ejemplo



Para una relación R y un atributo A

- N páginas de disco sirven de buckets
- Cada bucket cuenta con una lista ligada de overflow pages
- Usamos una función de hash h que me indicará que bucket le corresponde a cada valor:

h: dominio(A) \rightarrow [0, ..., N - 1]



Para buscar un elemento dada una search key k:

Se computa el valor de h(k)

costo O(1)

- Se accede al bucket correspondiente
- Se busca el elemento en la página asociada o una de sus overflow pages

Peor caso: costo $O(\lceil \frac{|R|}{B} \rceil)$

Cuando todo va a un casillero!

Caso ideal: costo 0

¿Cuándo no nos conviene utilizar un Hash Index?

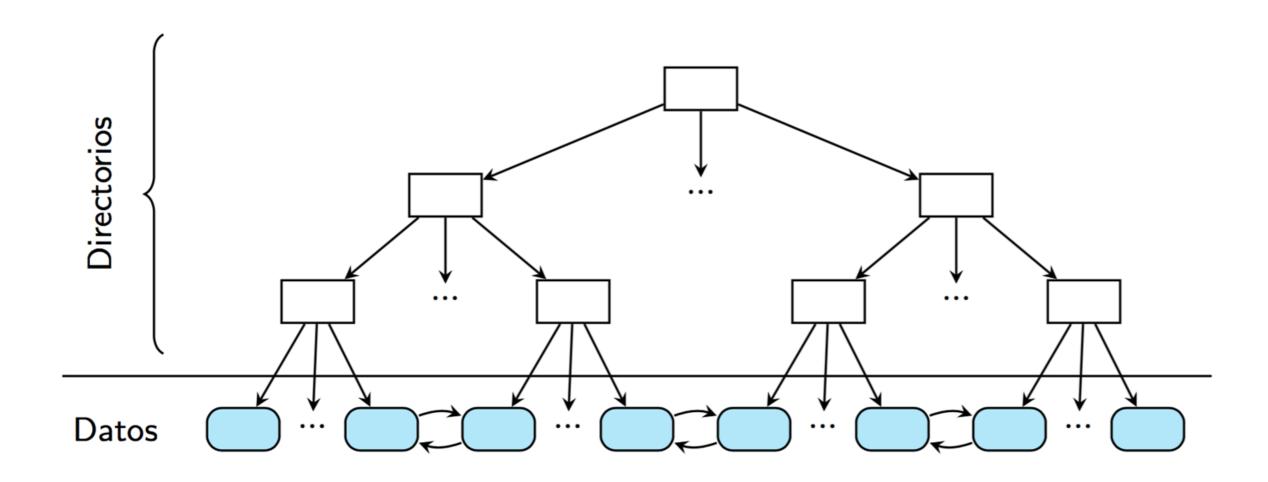
SELECT * FROM Artistas A WHERE A.aid > 12

Efectivamente: $\left\lceil \frac{|R|}{B} \right\rceil$

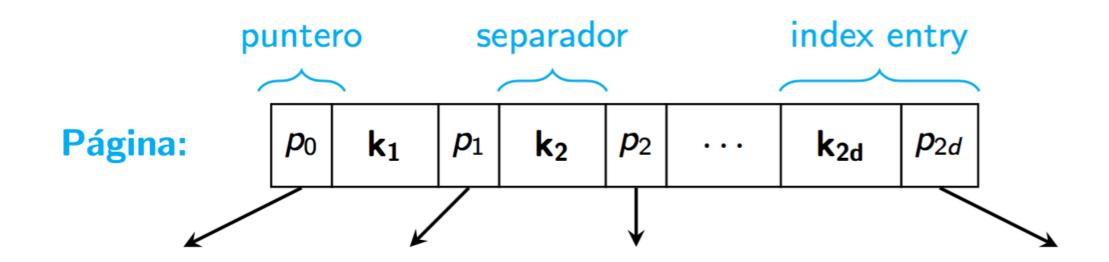
"B+ Trees are by far the most important access path structure in database and file systems", Gray y Reuter (1993).

Es un índice basado en un árbol:

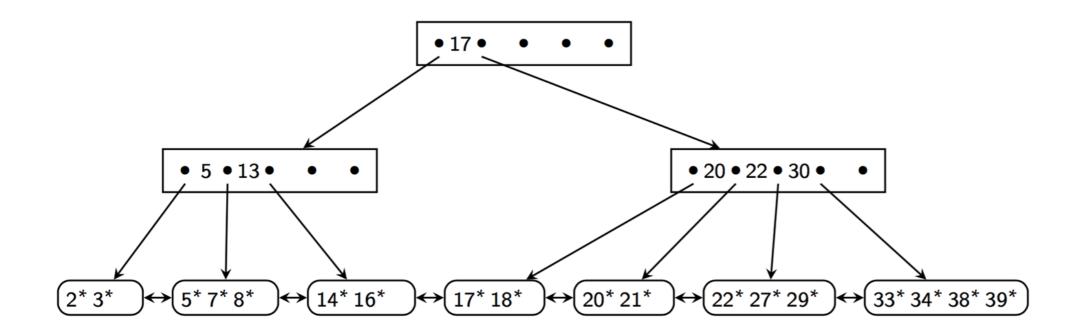
- Las páginas del disco representan nodos del árbol
- Las tuplas están en las hojas
- Provee un tiempo de búsqueda logarítmico
- Se comporta bien en consultas de rango
- Es el índice que usa Postgres sobre las llaves primarias (y en general, todos los sistemas)



Cada nodo del directorio tiene la siguiente forma:

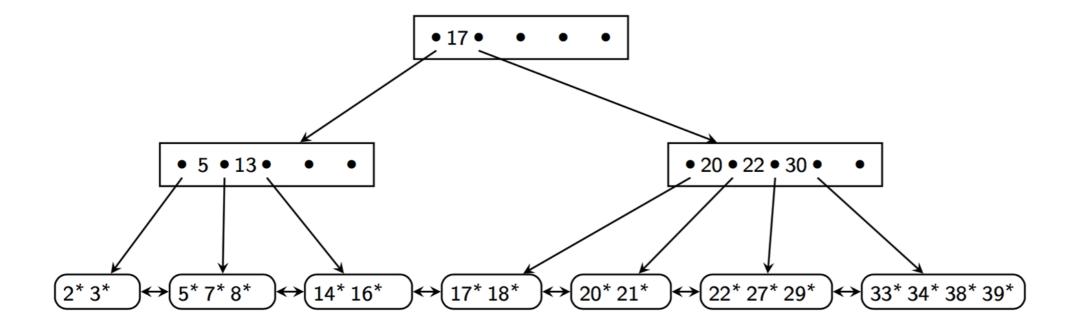


En los directorios, los nodos tienen una Search Key y un puntero antes y después de ella

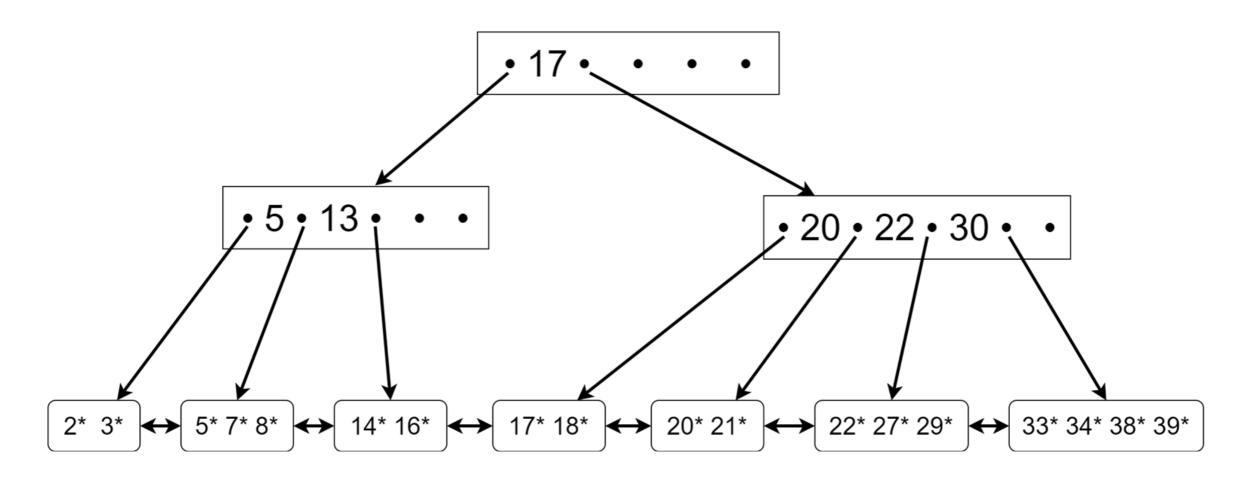


Ejemplo: consulta por un valor

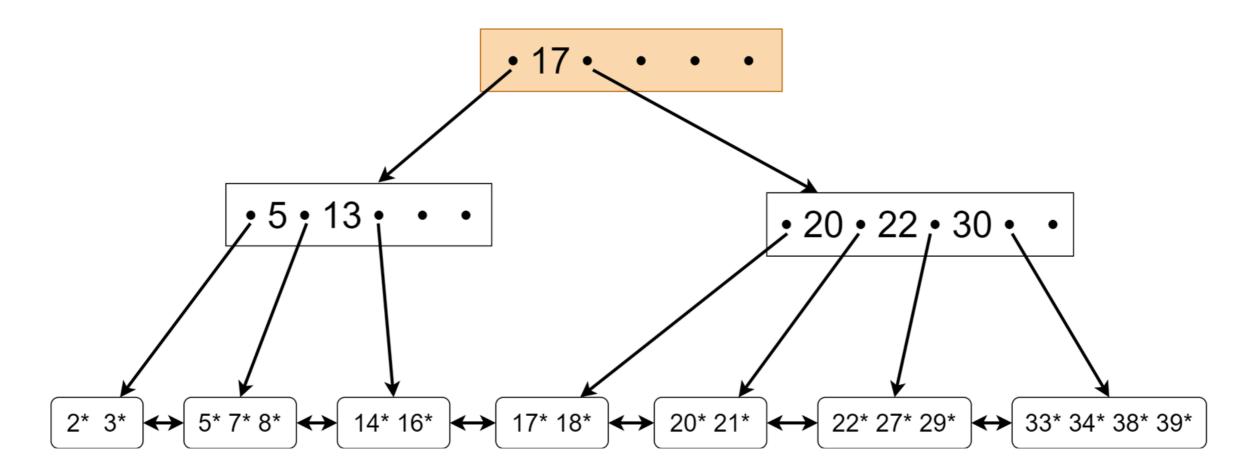
Supongamos que este índice también almacena artistas que están indexados por su aid



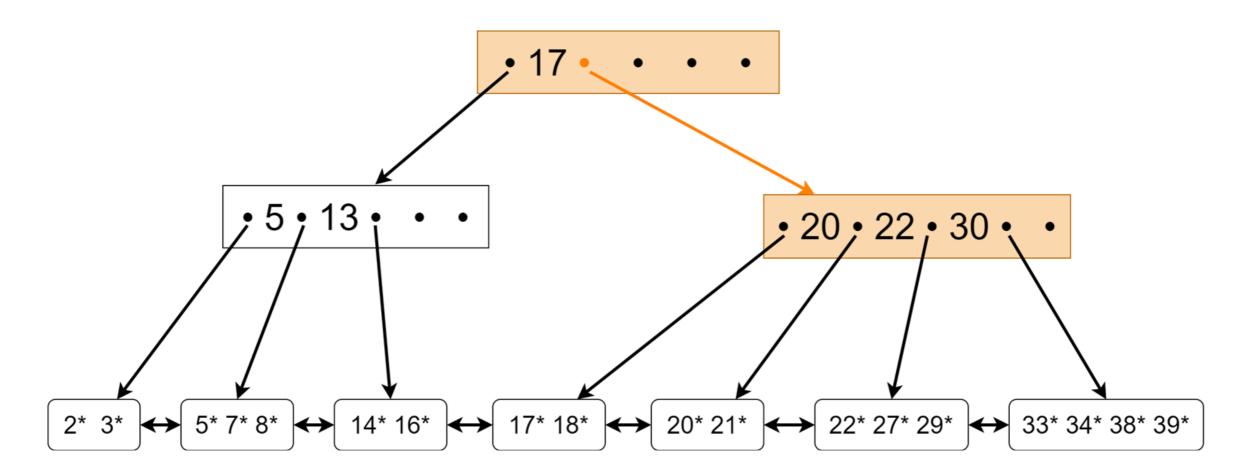
Ejemplo: consulta por un valor



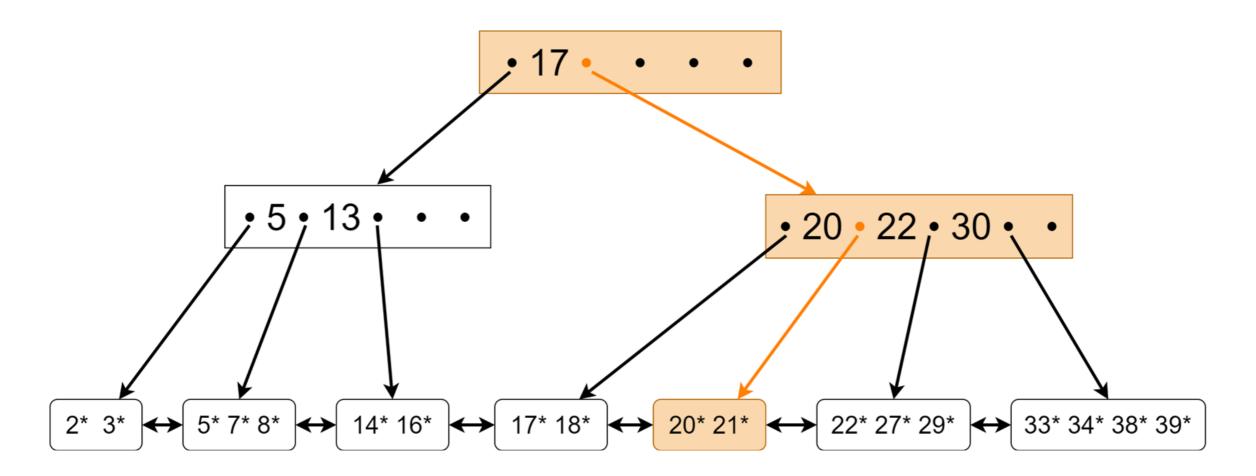
Ejemplo: consulta por un valor



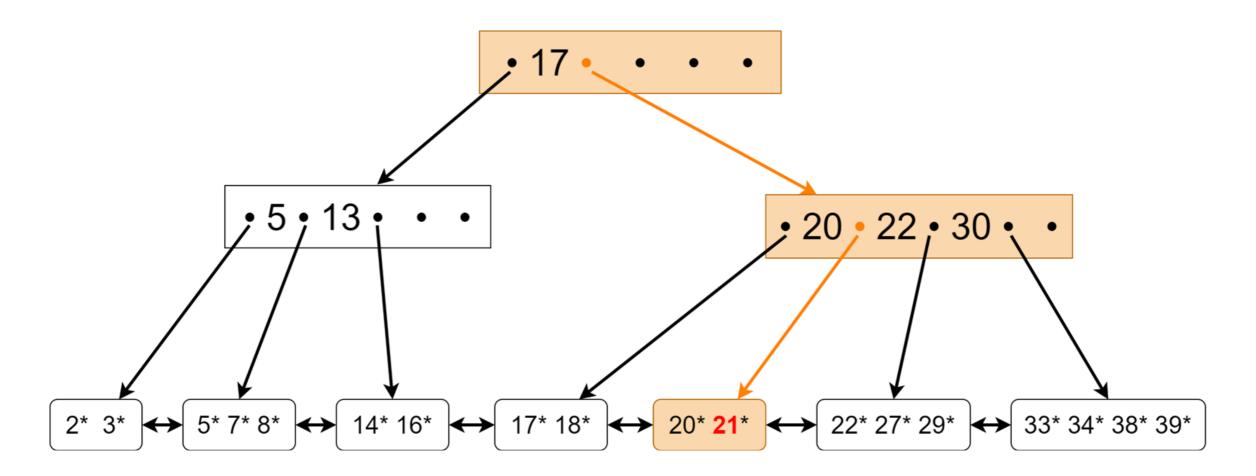
Ejemplo: consulta por un valor



Ejemplo: consulta por un valor

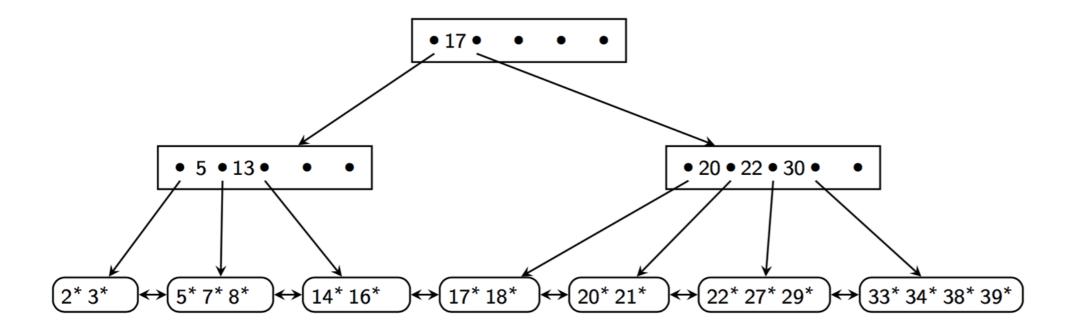


Ejemplo: consulta por un valor



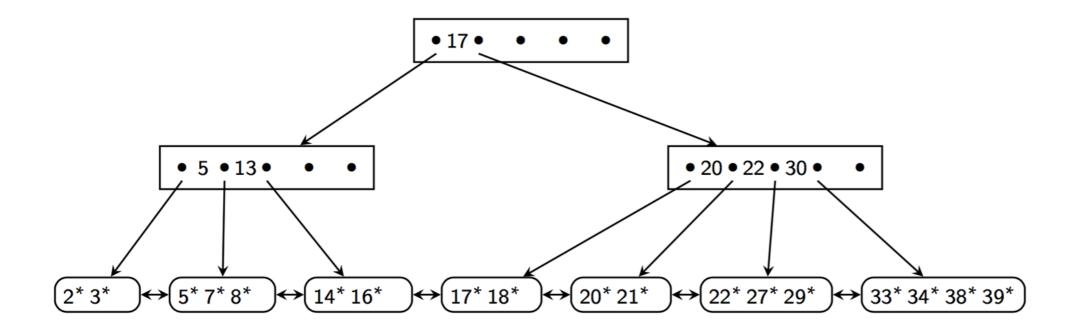
¿Y por qué este índice me sirve en consultas de rango?

Sabemos que las tuplas van a estar ordenadas según el atributo indexado, y además las hojas están encadenadas unas con otras

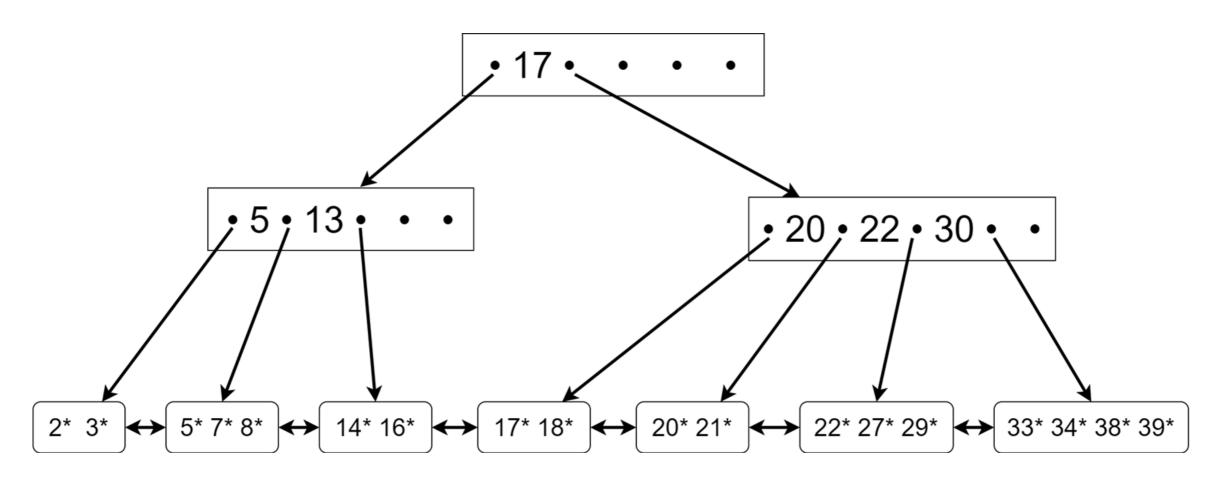


Ejemplo: consulta de rango

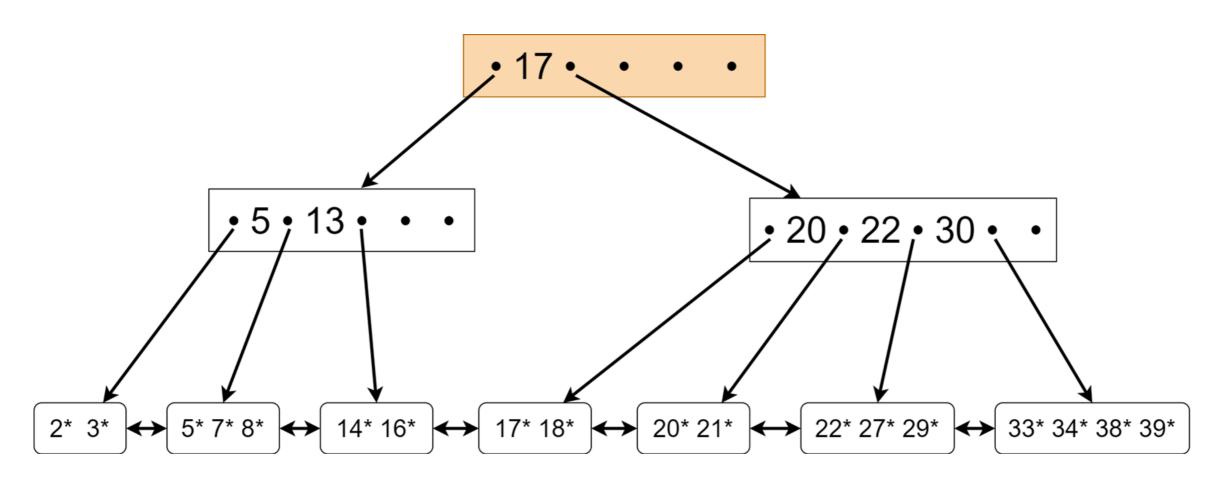
Ahora queremos hacer la consulta de todos los Artistas con aid entre 5 y 26



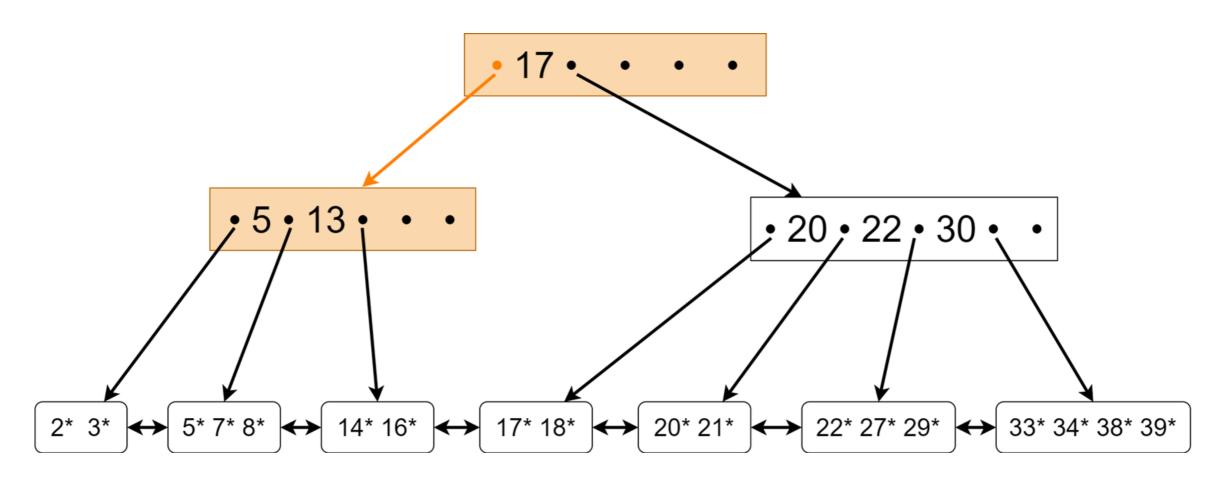
Ejemplo: consulta de rango



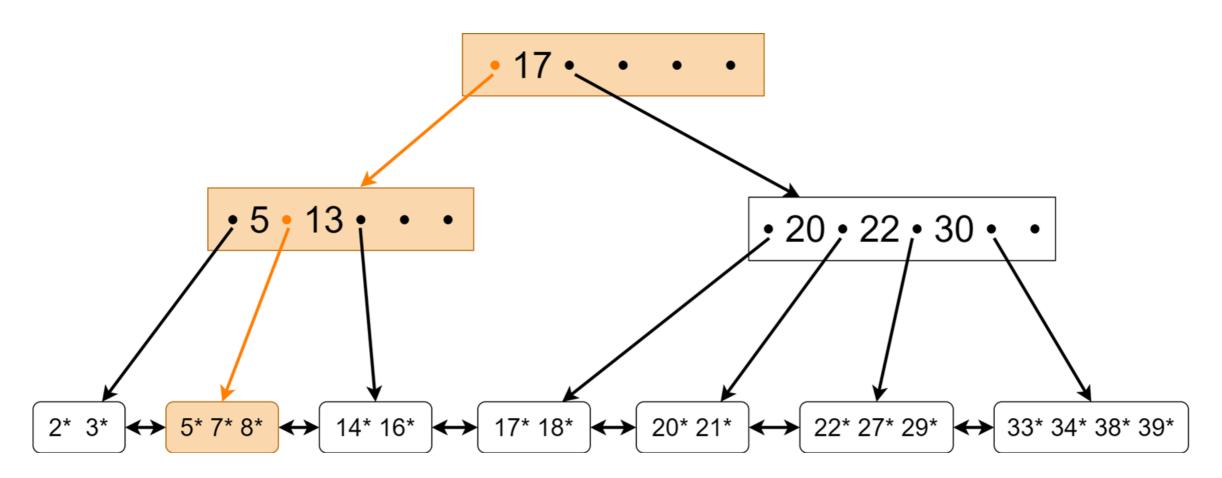
Ejemplo: consulta de rango



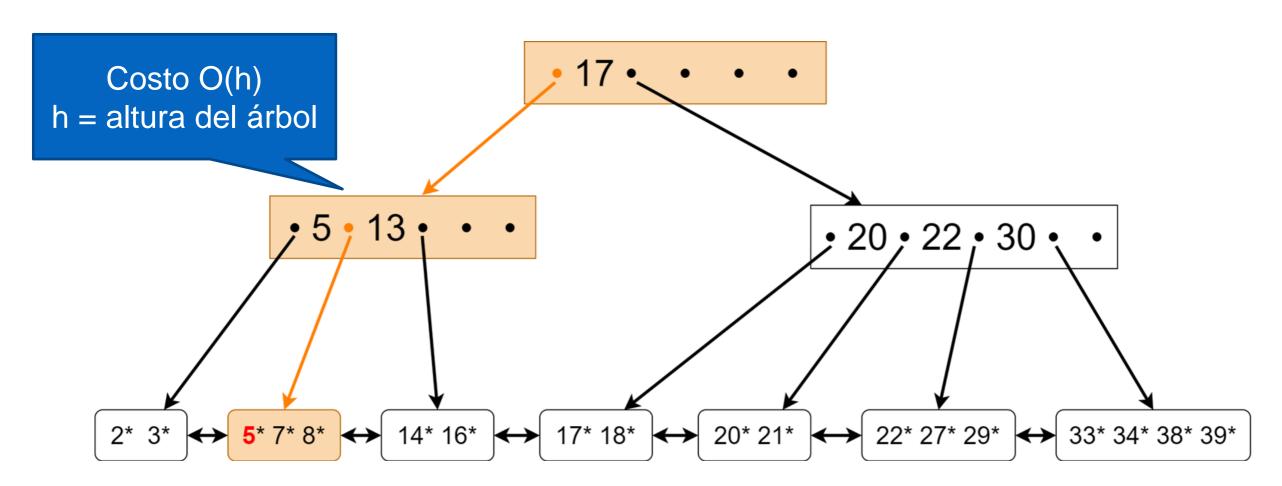
Ejemplo: consulta de rango



Ejemplo: consulta de rango

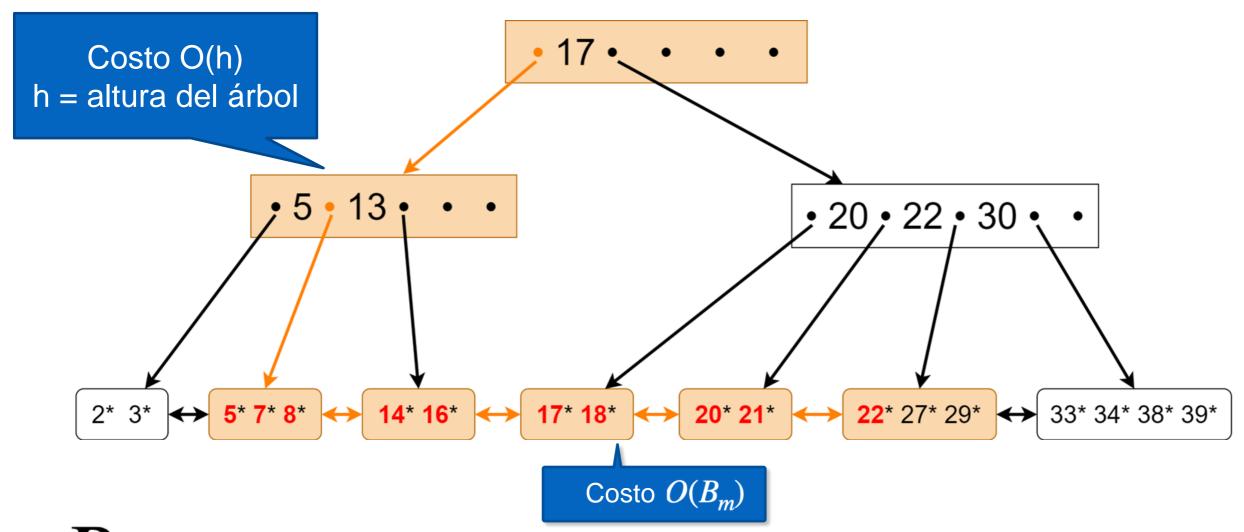


Ejemplo: consulta de rango



Ejemplo: consulta de rango

Todos los Artistas con aid entre 5 y 26



 $oldsymbol{B_m}$: nr de bloques con records que calzan búsqueda

Importante: para facilitar inserción de datos nuevos los B+ trees no tienen nodos completamente llenos

Típicamente se dice que las hojas están ocupadas a un porcentaje; e.g. 60% -- quiere decir si caben 100 tuplas hay solo 60 en una página de la hoja

El costo de búsqueda es logarítmico $\sim log(|R|)$

Si **B** es el tamaño de una página en tuplas, el costo de búsqueda es:

$$O(log_B(\left\lceil \frac{|R|}{B} \right\rceil))$$

¿Qué pasa si el índice lo mantenemos en memoria RAM?

Tipos de valores a guardar

Un índice me puede retornar:

- La tupla que estoy buscando
- Un puntero o lista de punteros a las páginas del disco duro que tienen las tuplas que estoy buscando

Clustered y Unclustered Index

Data entry: La tupla misma

Hablaremos de un índice **Clustered** si al preguntarle por un valor me retorna una tupla

Hablaremos de un índice **Unclustered** si me retorna un puntero

Data entry:
Puntero a la página
con mi tupla

Clustered y Unclustered Index

Clustered Index se conoce como índice primario

Unclustered Index se conoce como índice secundario

Clustered y Unclustered Index

Considere Empleados(id, nombre, edad)

Un índice primario en general se aplica sobre la primary key, por ejemplo el id de los empleados

Un índice secundario se aplica sobre un atributo como edad (para ordenar por edad más rápido)

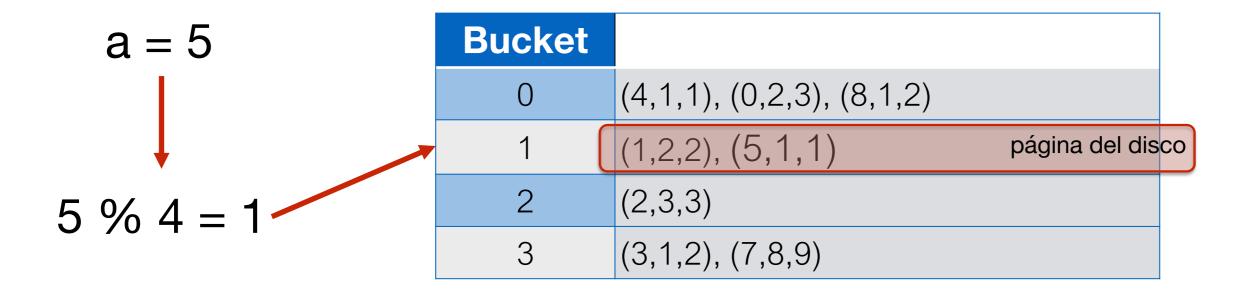
Buscando una tupla con distintos tipos de índices

R(a,b,c) ... índice sobre a

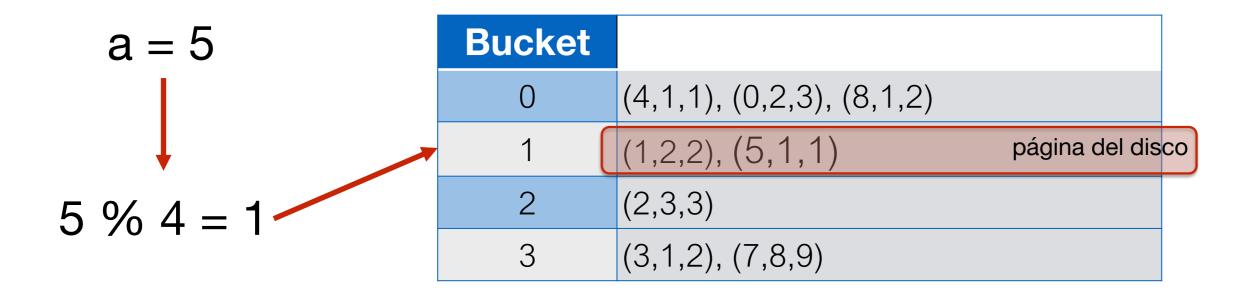


Bucket	
0	(4,1,1), (0,2,3), (8,1,2)
1	(1,2,2), (5,1,1)
2	(2,3,3)
3	(3,1,2), (7,8,9)

R(a,b,c) ... índice sobre a

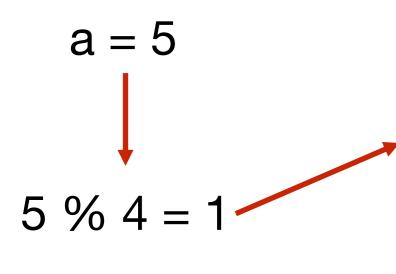


R(a,b,c) ... índice sobre a



#(I/O) = 1 (el bucket es la página con mi tupla)

R(a,b,c) ... índice sobre a



Bucket	
0	(4,p1), (0,p2), (8,p3)
1	(1,p1), (5,p1)
2	(2,p2)
3	(3,p2), (7,p3)

Datos en el disco:

(4,1,1), (1,2,2), (5,1,1)

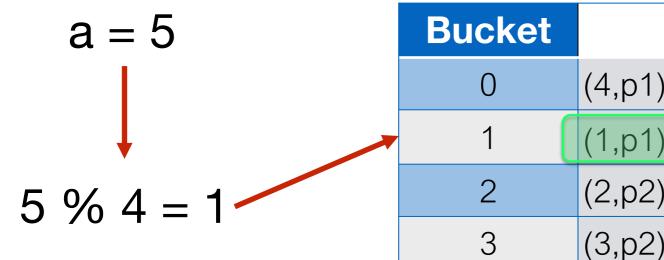
p2

(0,2,3), (3,1,2), (2,3,3)

р3

(7,8,9), (8,1,2)

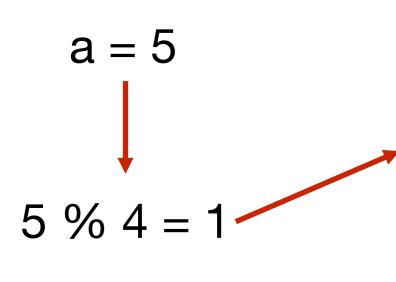
R(a,b,c) ... índice sobre a



Bucket		
0	(4,p1), (0,p2), (8,p3)	
1	(1,p1), (5,p1)	página del disc
2	(2,p2)	
3	(3,p2), (7,p3)	

Datos en el disco:

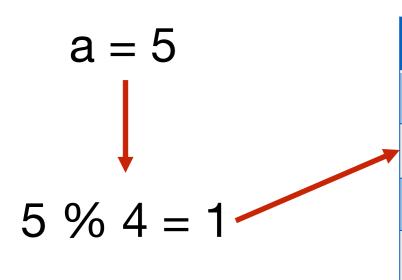
R(a,b,c) ... índice sobre a



Bucket			
0	(4,p1), (0,p2), (8,p3)		
1	(1,p1), (5,p1)	página del dis	СО
2	(2,p2)		
3	(3,p2), (7,p3)		

Datos en el disco:

R(a,b,c) ... índice sobre a



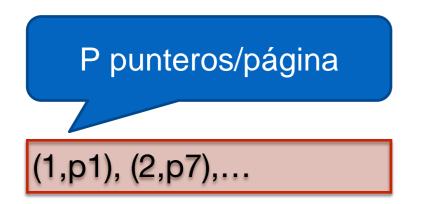
Bucket		
0	(4,p1), (0,p2), (8,p3)	
1	(1,p1), (5,p1)	página del disco
2	(2,p2)	
3	(3,p2), (7,p3)	

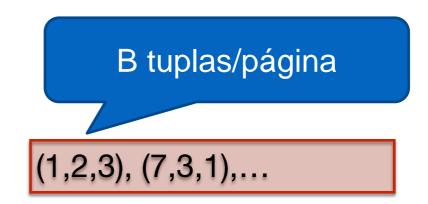
Datos en el disco:

$$\#(I/O) = 2$$

R(a,b,c) ... índice sobre a

Considerar: página del índice vs página con tuplas



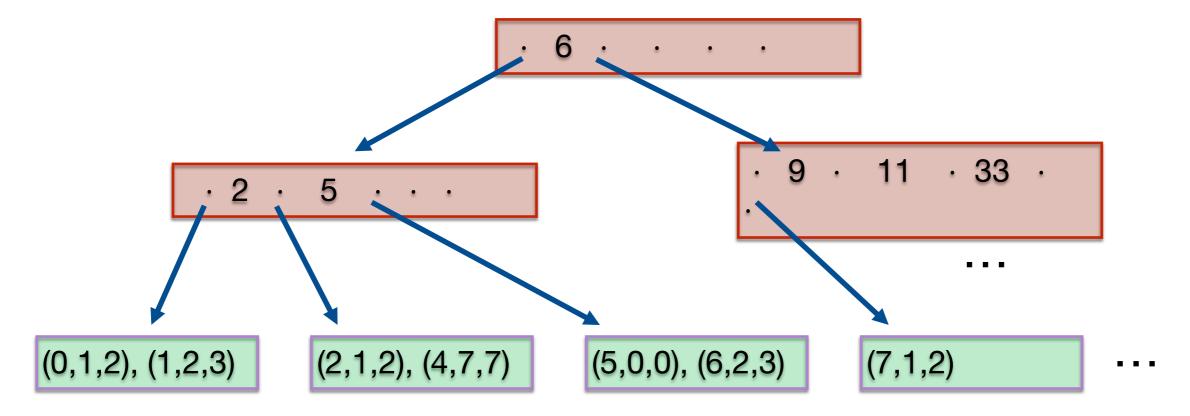


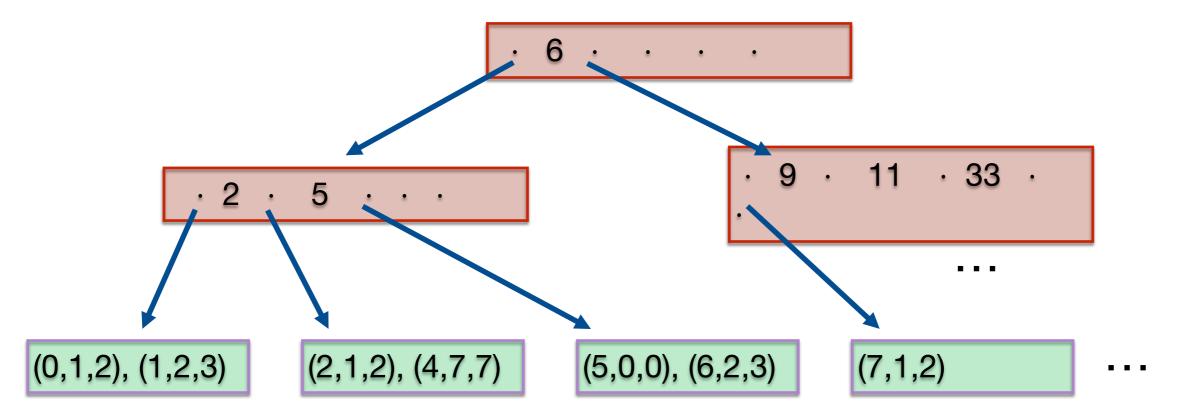
puntero p1 ... un long/8 bytes

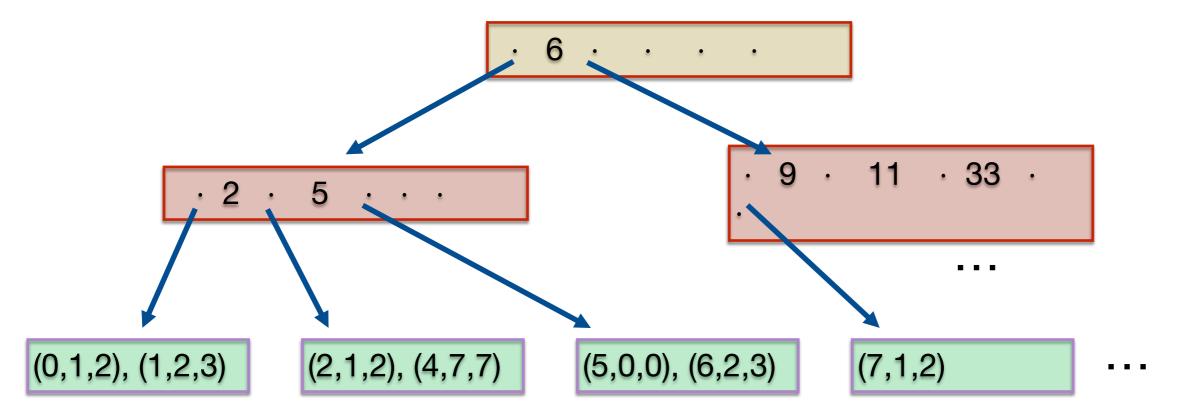
tupla ... puede ser 20 longs/160 bytes

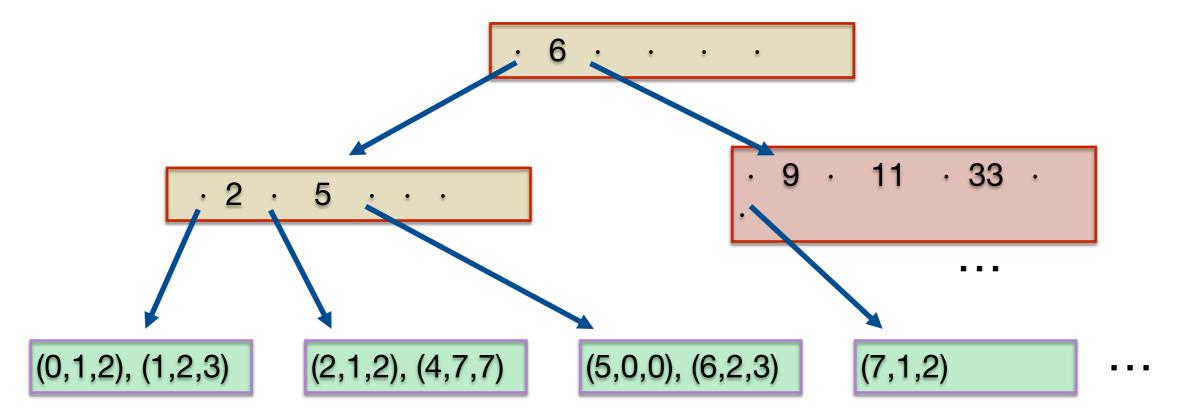
¿Dónde cabe más? (P>B)

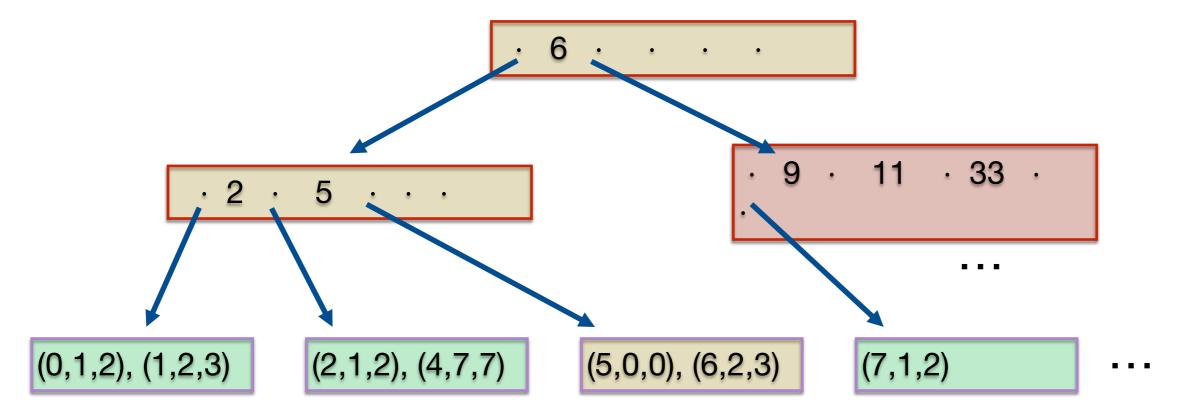
R(a,b,c) ... índice sobre a



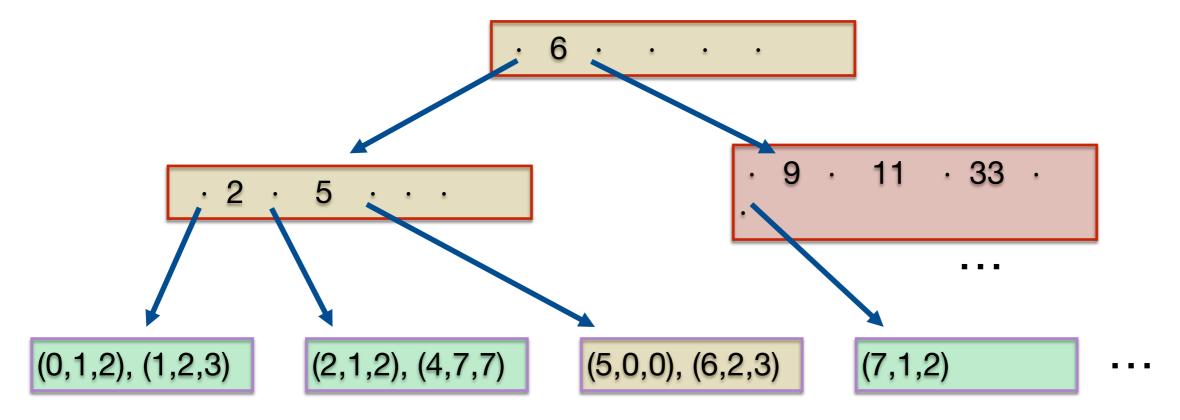






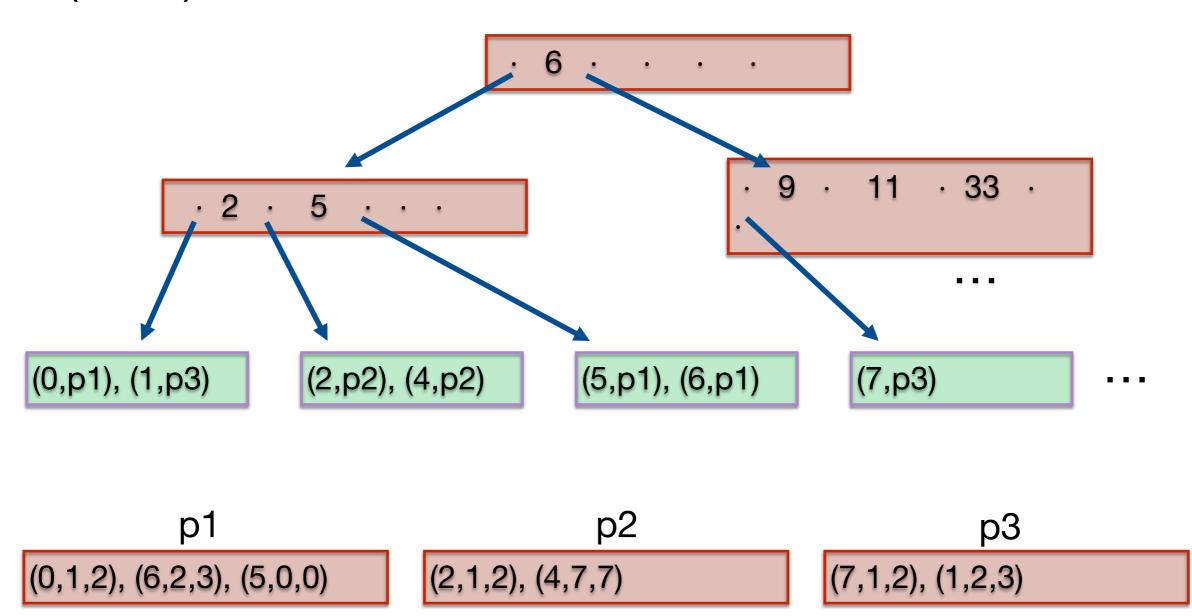


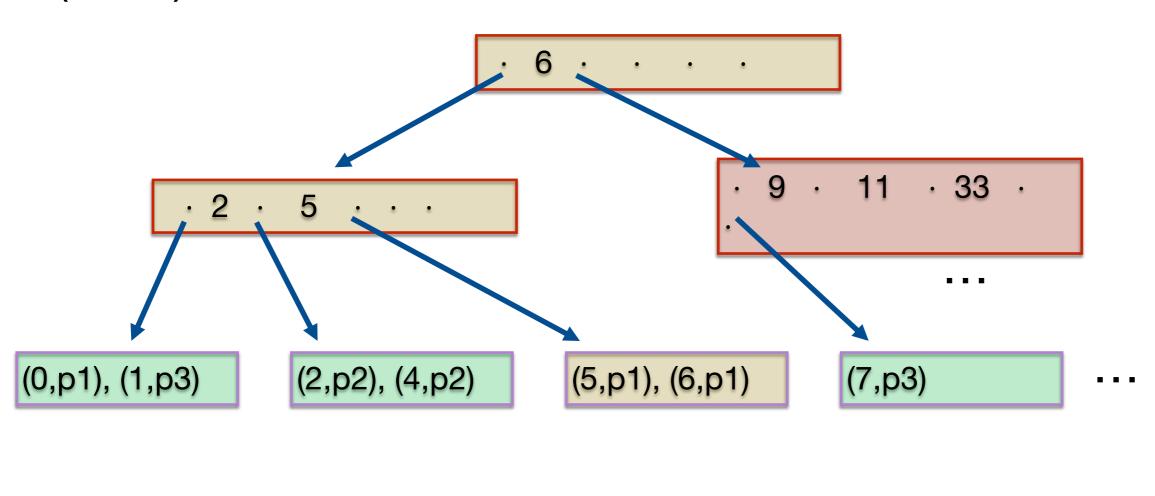
 $R(\underline{a},b,c)$... indice sobre a ... a = 5

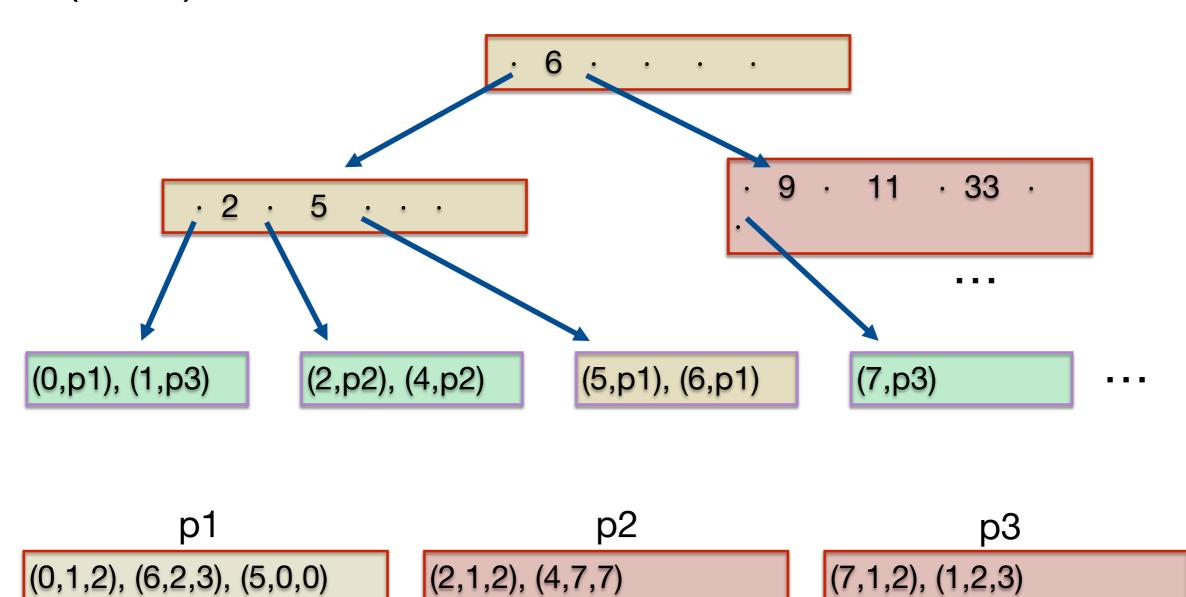


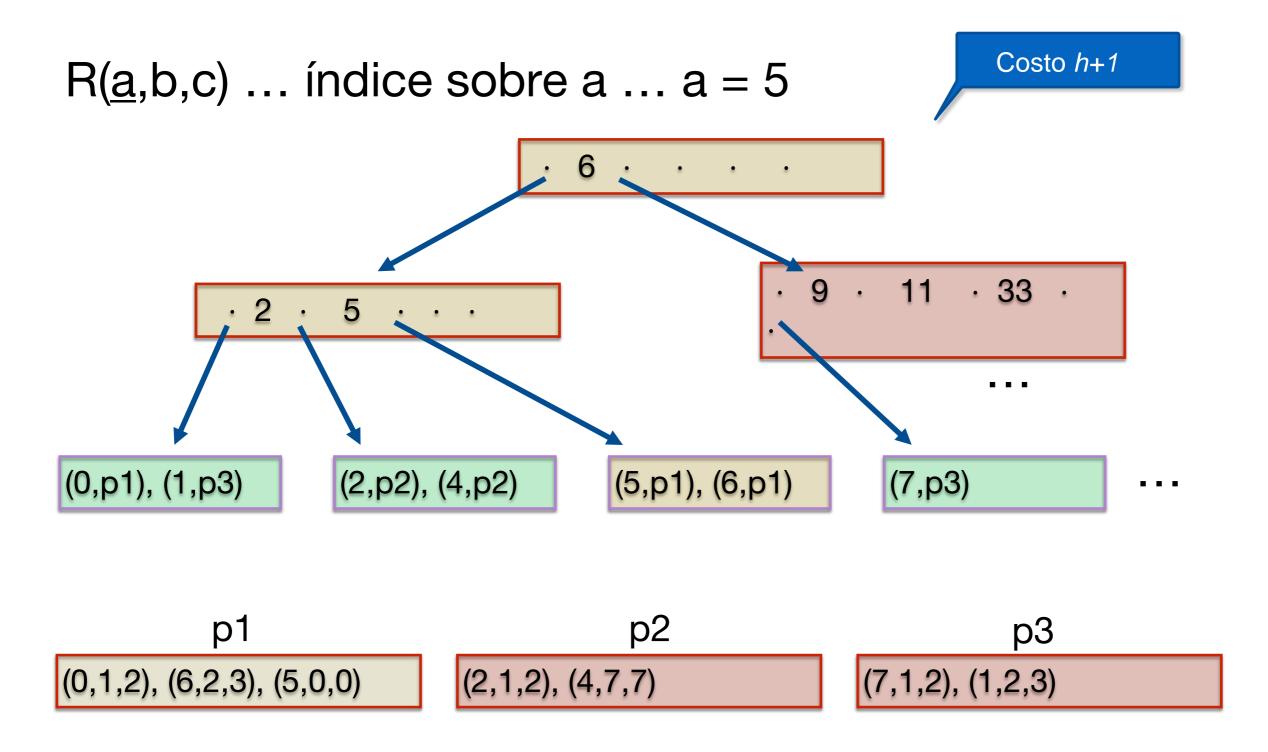
#(I/O) = h ... altura del árbol (los datos están en hojas)

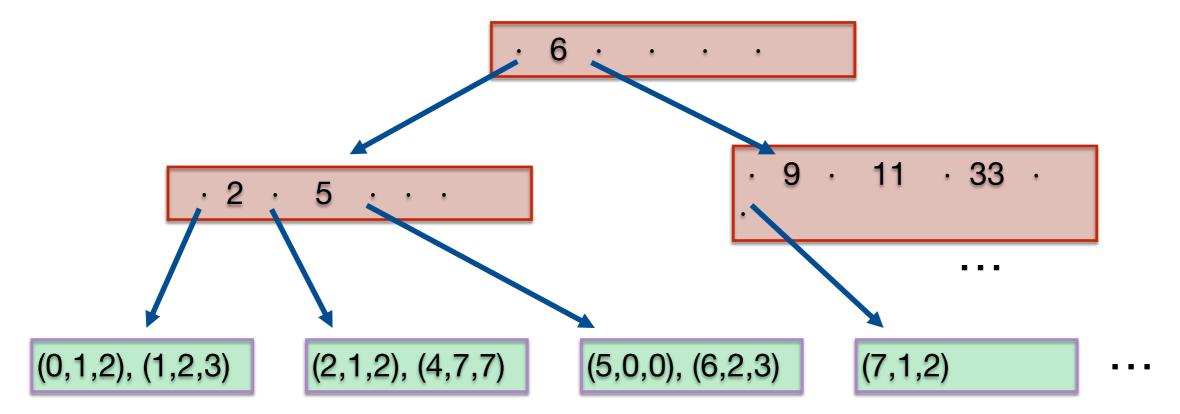
R(a,b,c) ... índice sobre a

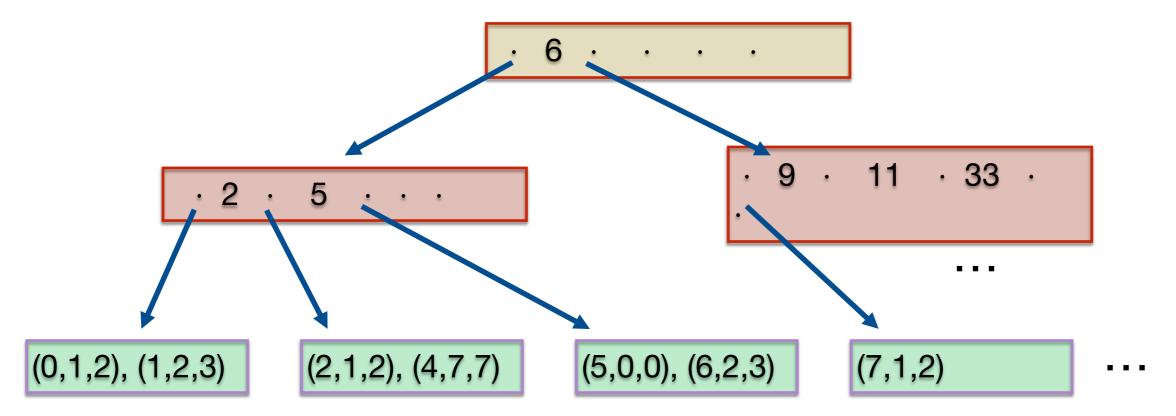


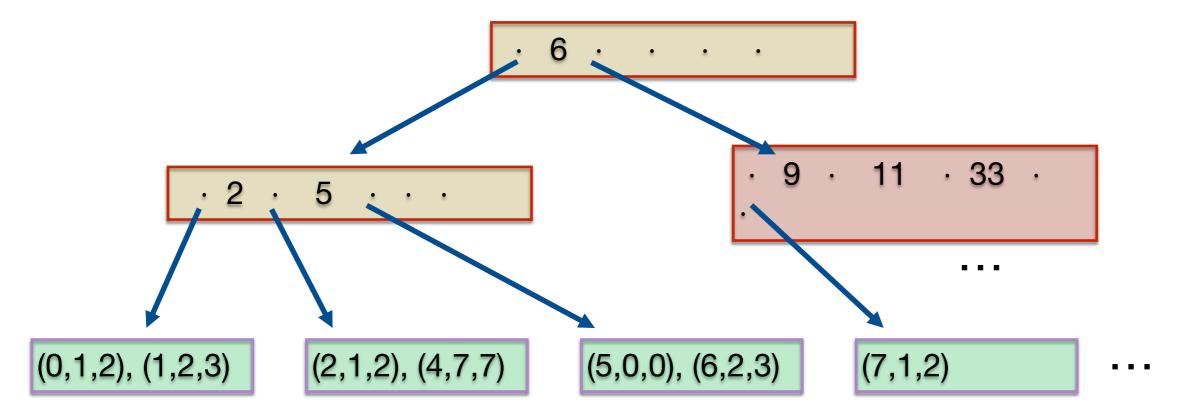


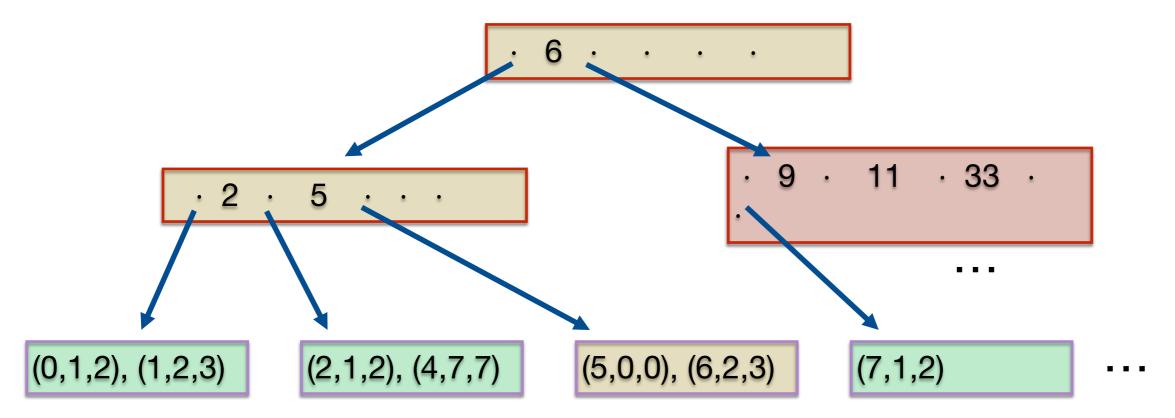


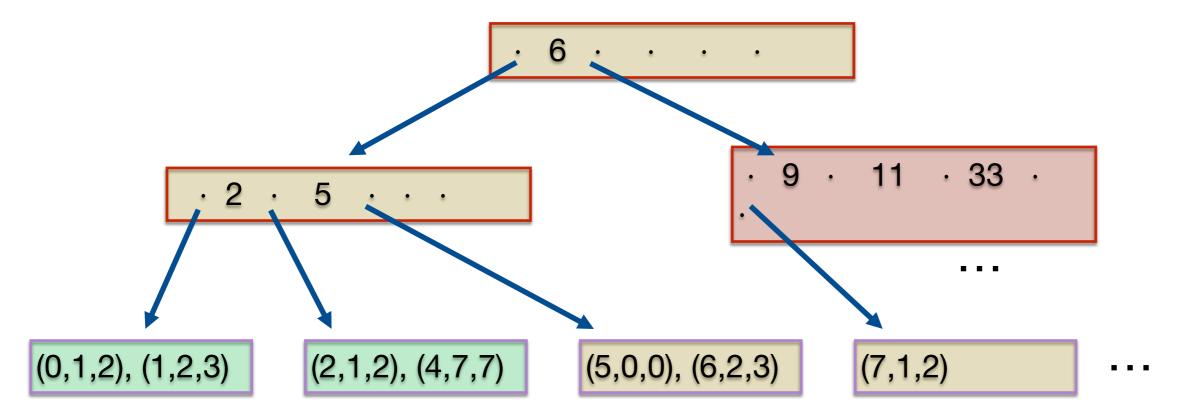




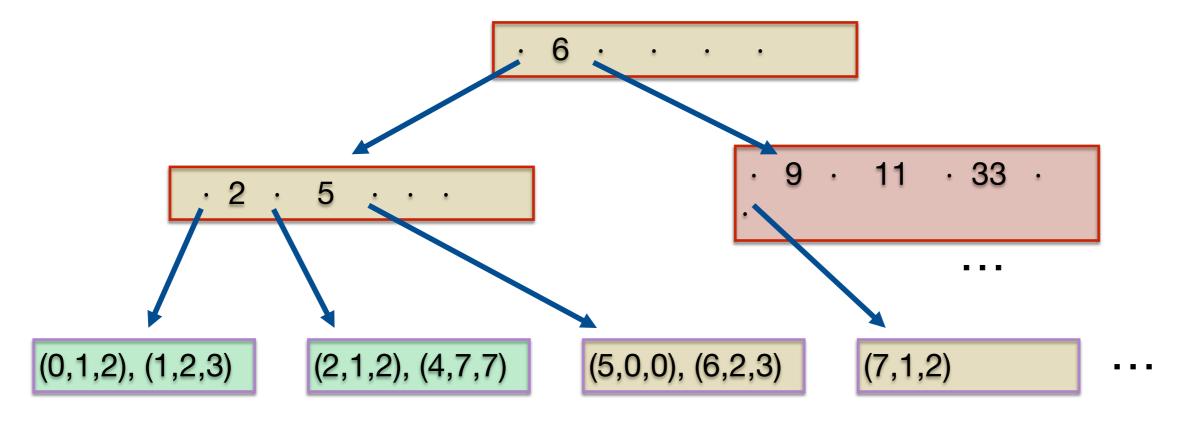






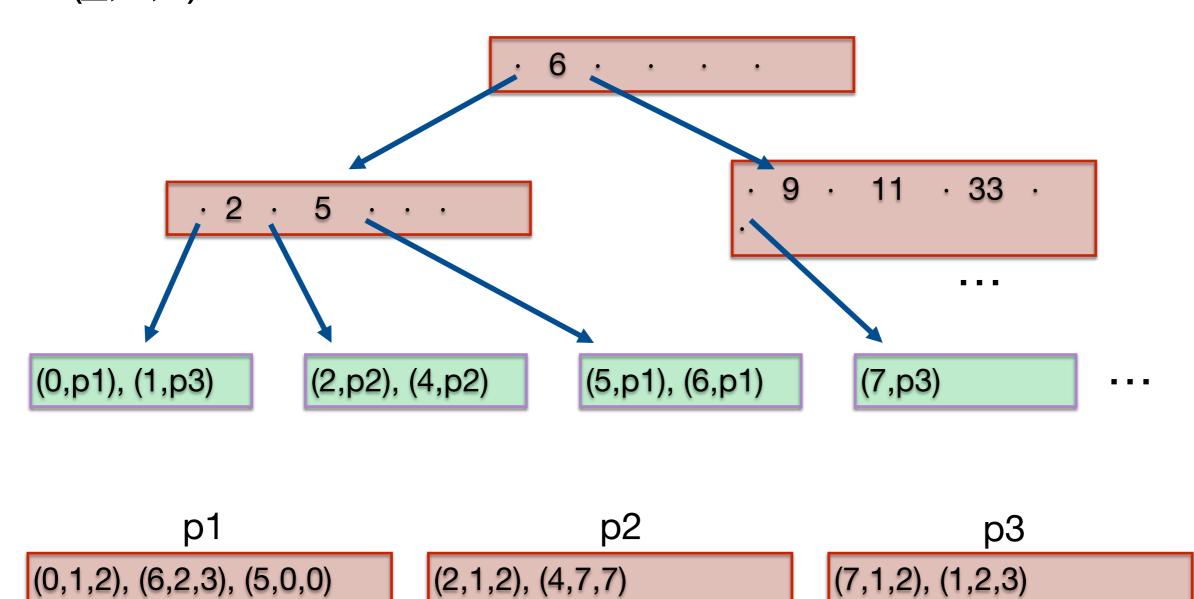


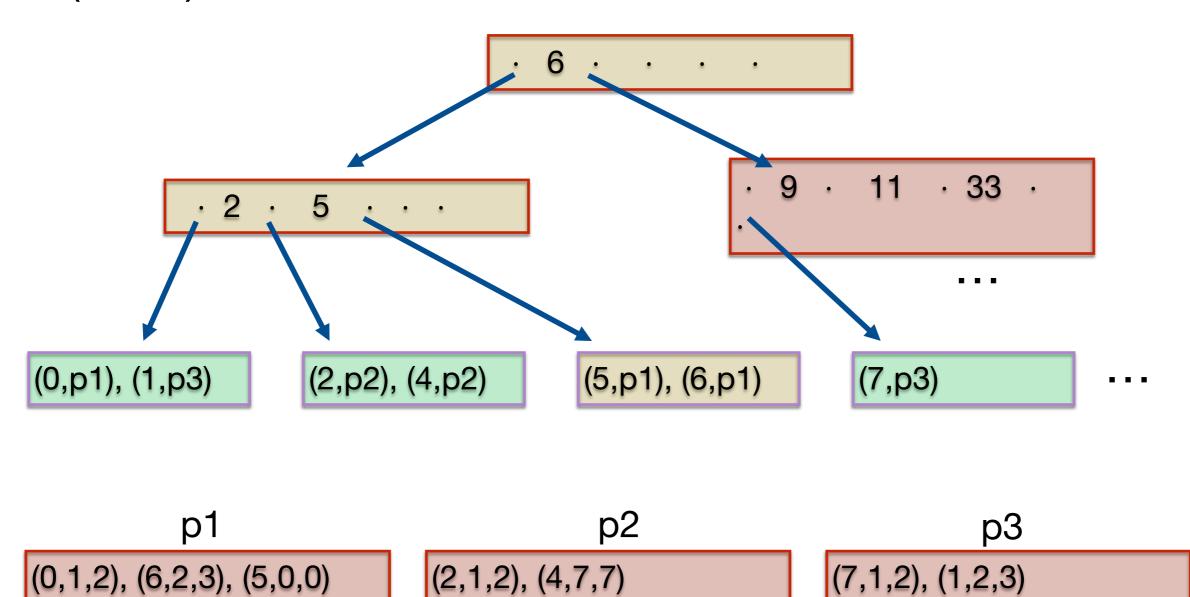
 $R(\underline{a},b,c)$... indice sobre a ... a > 5

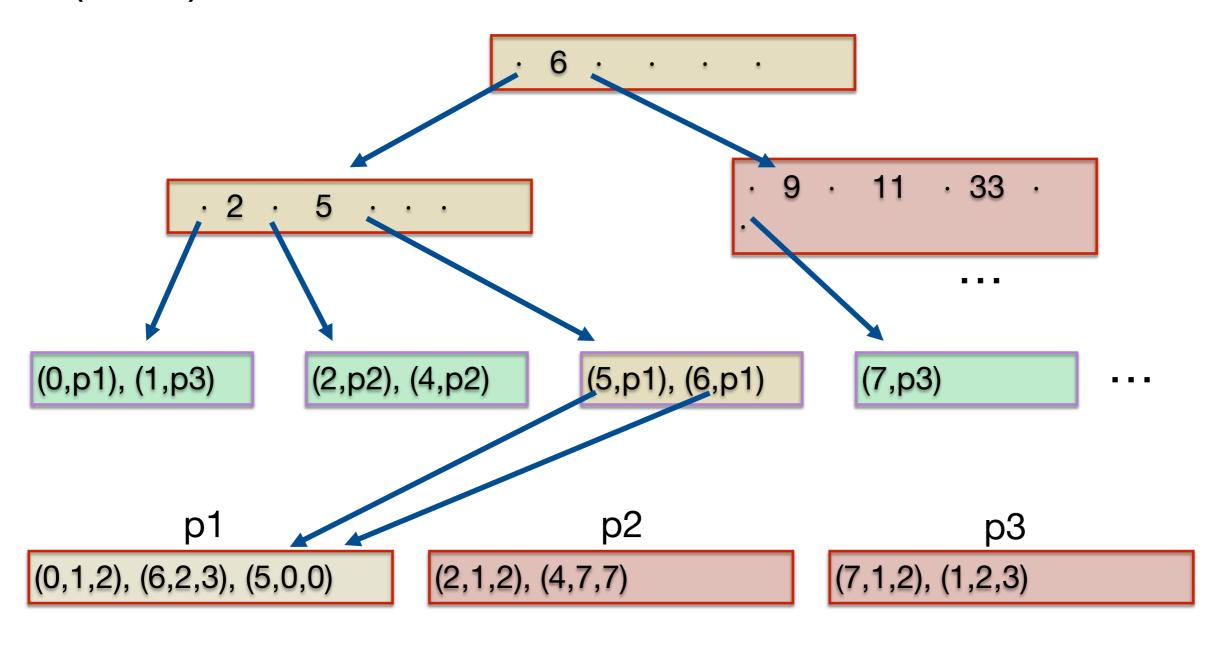


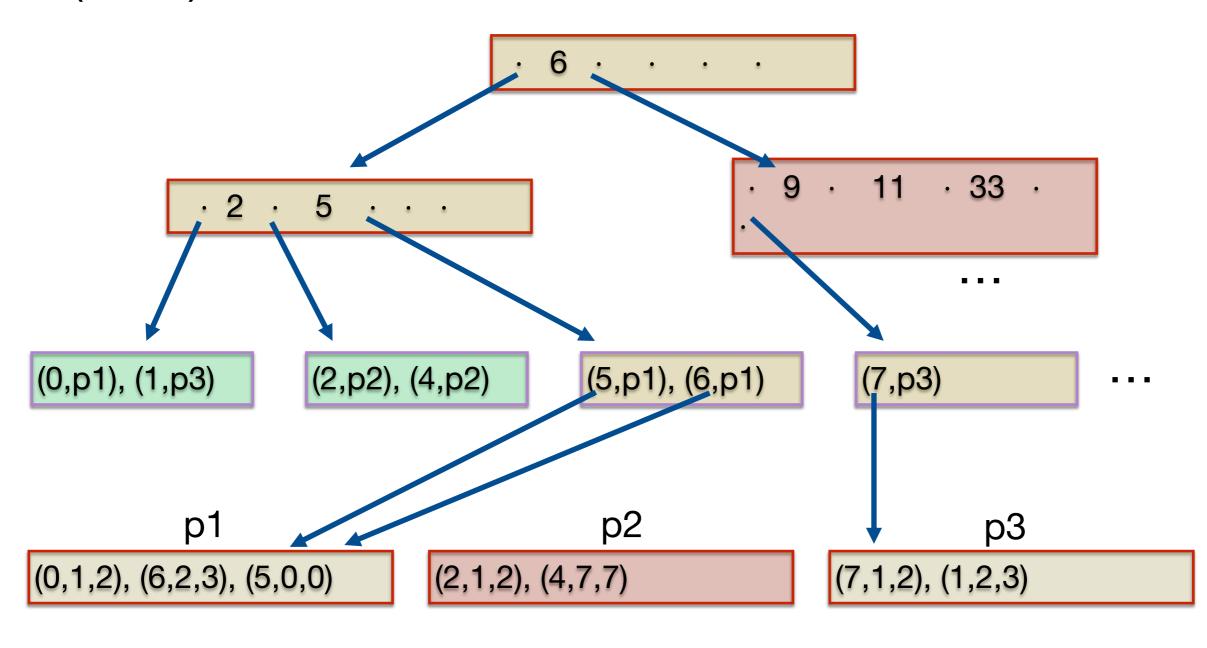
$$\#(I/O) = h + B_m$$

 $oldsymbol{B_m}$: nr de bloques con tuplas que calzan búsqueda



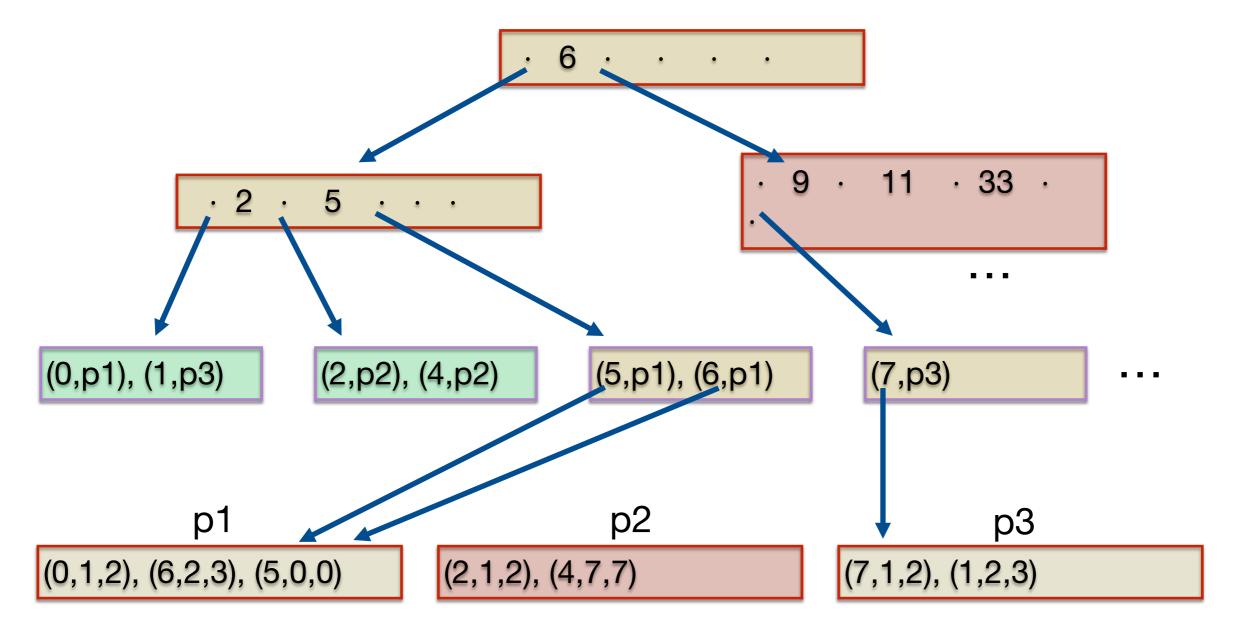






$$\#(I/O) = h + \left\lceil \frac{n}{P} \right\rceil + n$$

n : número de tuplas que calzan con búsquedasP : Cantidad de punteros por bloque



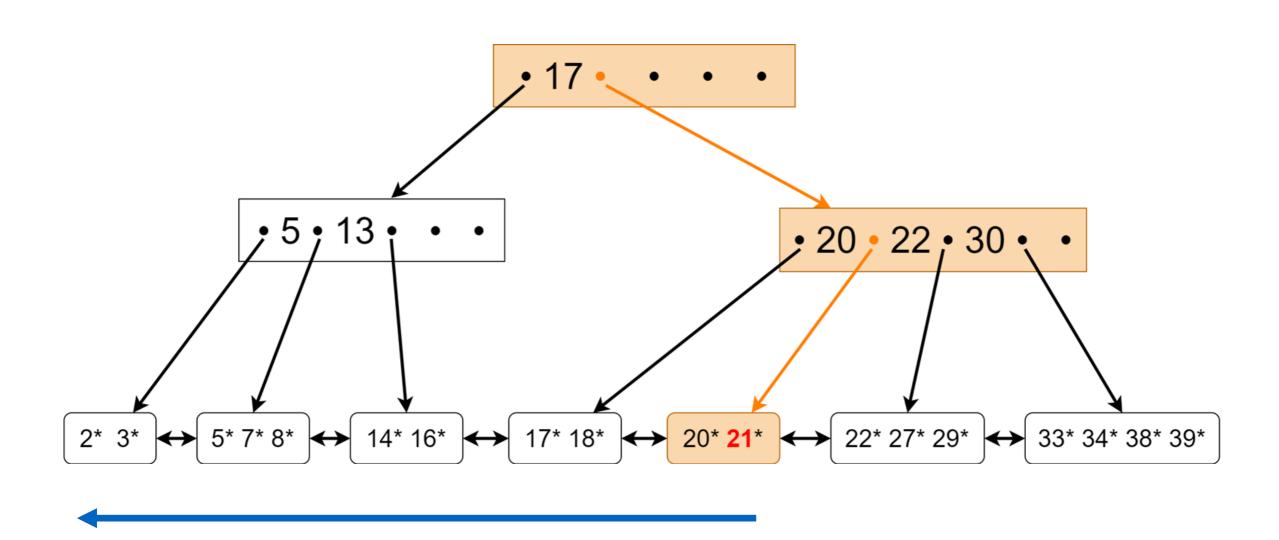
$R(\underline{a},b,c)$:

- 1M tuplas
- valor de <u>a</u> distribuido uniformamente en [0,1.000.000]
- B tuplas por página
- P > B punteros en una página (hojas a 100% ocupación)
- h altura del B+ tree

SELECT * FROM R WHERE a<21

Costo:

- Buscar a = 21 ... h
- Scan hacia la izquierda



$R(\underline{a},b,c)$:

- 1M tuplas
- valor de <u>a</u> distribuido uniformamente en [0,1.000.000]
- B tuplas por página
- P > B punteros en una página (hojas a 100% ocupación)
- h altura del B+ tree

Costo:

- Buscar $a = 21 \rightarrow h$
- Por uniformidad + a es llave para a=21 → 21 tuplas
- Cúantos punteros hay en una página? → 21/P
- Más buscar la página en el disco (unclustered) -> 21

$$h + (21/P - 1) + 21$$

R(<u>a</u>,b,c):

- 1M tuplas
- valor de <u>a</u> distribuido uniformamente en [0,1.000.000]
- B tuplas por página
- P > B punteros en una página (hojas a 100% ocupación)
- h altura del B+ tree

Costo:

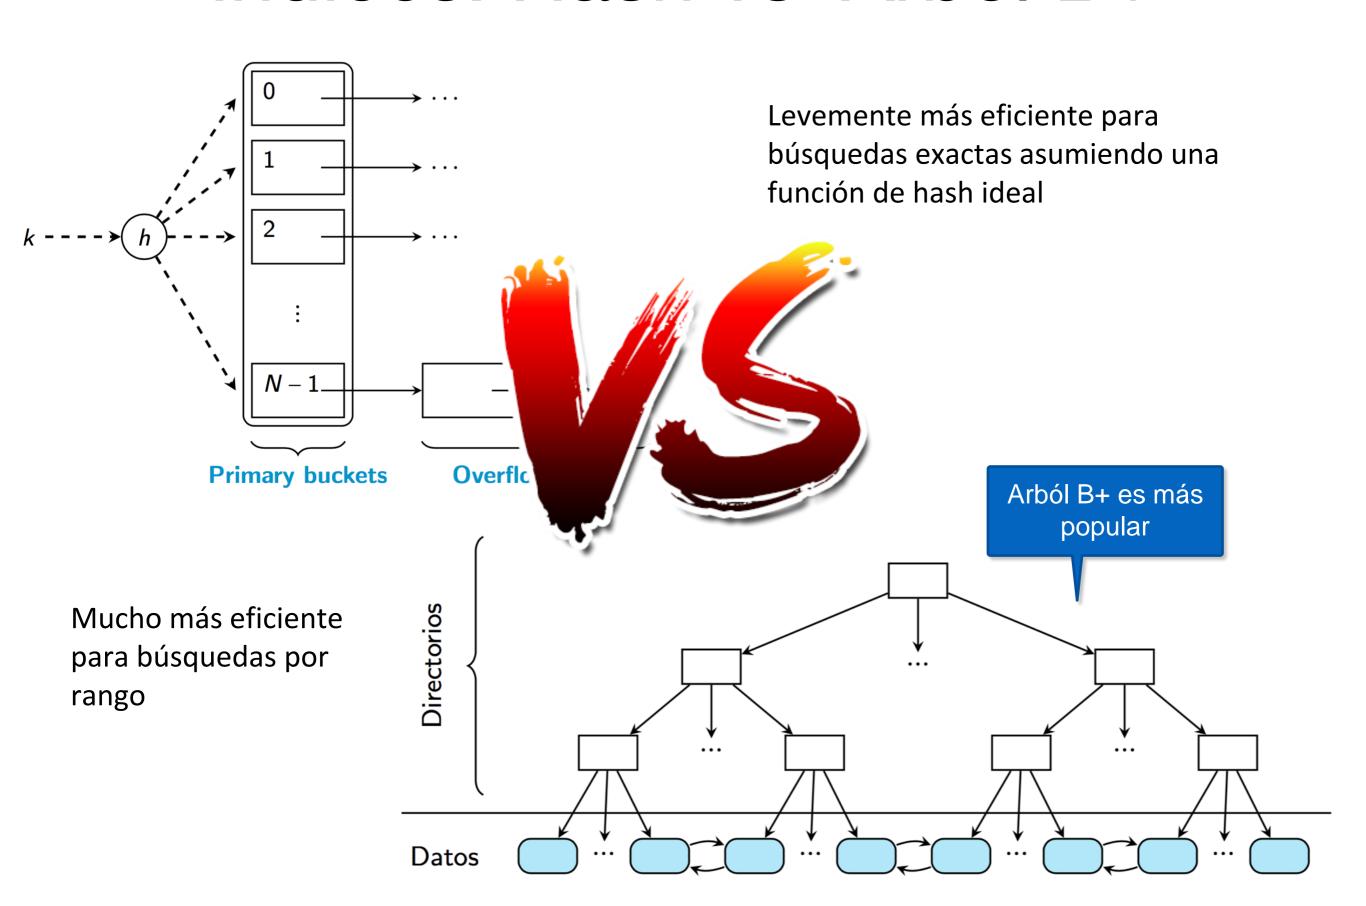
h + (21/P - 1) + 21

Bajar hacia a = 21

Scan a izquierda hay P punteros/página

Para cada a recibo puntero, no la tupla

Índices: Hash vs. Árbol B+



Para más detalles: IIC3413 - Implementación de sistemas de Bases de Datos